FACULTAD DE INGENIERÍA

CARRERA DE INGENIERÍA DE SISTEMAS COMPUTACIONALES

INFORME DE PROYECTO FINAL

BASE DE DATOS AVANZADAS Y BIG DATA

Solución de Inteligencia de Negocios

Solución de Inteligencia de Negocios para la Gestión de Ventas en una Tienda en Línea (Online Retail)

DATOS DEL EQUIPO	INFORMACIÓN	
Autores	BUENO FERNANDEZ, Cesar Fabrizzio	100%
	HERRADA VELA, Estefanno Arturo	100%
	HUERTAS PEREZ, Juan Angel	100%
	IMAN GIRALDO, Alexander Tomas	100%
	PILCO SOSA, Samanta Sofia	100%
Docente	**VICTOR ISAAC CHAVEZ BARDALES**	
Curso / NRC	Base de Datos Avanzadas y Big Data / Pendiente *(código de la sección del curso, visible en el campus virtual).*	
Repositorio	https://github.com/Juanhp07/Base-de-datos-Avanzada-y-Big-Data-Proyecto (rama main, commit 5e06932)	
Período	2026-2	

Ciudad - Perú

2026

ÍNDICE

INDICE

RESUMEN 4

ABSTRACT 5

CAPÍTULO I: CONTEXTO, PROBLEMA Y OBJETIVOS 6

1.1 Contexto y necesidad empresarial 6

1.2 Formulación del problema de ingeniería 7

1.3 Objetivos 8

1.4 Alcance, restricciones y supuestos 8

1.5 Stakeholders y criterios de éxito 9

1.6 Fuentes, gobierno y ética de los datos 10

CAPÍTULO II: ANTECEDENTES Y FUNDAMENTOS 11

2.1 Antecedentes 11

2.2 Fundamentos de Inteligencia de Negocios 13

2.3 Fundamentos de Big Data 14

2.4 Tecnologías, estándares y trabajos relacionados 16

CAPÍTULO III: DISEÑO DE INGENIERÍA DE LAS SOLUCIONES 17

3.1 Requerimientos funcionales y no funcionales 17

3.2 Alternativas y decisiones de arquitectura 20

3.3 Arquitectura integrada y flujo de datos 22

3.4 Diseño de la solución de Inteligencia de Negocios 24

3.4.1 Requisitos, usuarios e indicadores 24

3.4.2 Modelo dimensional y datamart 28

3.4.3 Procesos ETL/ELT y calidad 32

3.4.4 OLAP, reportes y dashboards 36

3.5 Diseño de la solución Big Data 37

3.5.1 Justificación y requisitos Big Data 38

3.5.2 Arquitectura y componentes 38

3.5.3 Modelo y ciclo de vida de datos 38

3.5.4 Escalabilidad, resiliencia y operación 38

3.5.5 Resultados 38

3.6 Seguridad, privacidad y riesgos 38

3.7 Plan de despliegue y aceptación 40
CAPÍTULO IV: DISEÑO DEL EXPERIMENTO 41
4.1 Pregunta experimental, objetivo e hipótesis 41
4.2 Escenario y datasets 42
4.3 Variables, métricas y criterios de aceptación 43
4.4 Entorno, herramientas y reproducibilidad 45
4.5 Matriz de escenarios experimentales 46
4.6 Procedimiento reproducible 48
4.7 Riesgos, validez y limitaciones del experimento 48
CAPÍTULO V: IMPLEMENTACIÓN Y CONTROL DE EVIDENCIAS 49
5.1 Estructura y versión del repositorio 49
5.2 Implementación de la solución BI 50
5.3 Implementación de la solución Big Data 50
5.4 Calidad, seguridad y pruebas 50
5.5 Registro de retroalimentación y mejoras 52
5.6 Contribuciones individuales 53
5.7 Declaración de uso responsable de inteligencia artificial 55
CAPÍTULO VI: EJECUCIÓN, RESULTADOS Y ANÁLISIS DE DATOS 57
6.1 Validación del dataset original y procesado 57
6.2 Registro de ejecuciones 58
6.3 Tabla consolidada de resultados 60
6.4 Visualizaciones y dashboards 61
6.5 Análisis e interpretación técnica 63
6.6 Verificación de funcionalidad y completitud 66
CAPÍTULO VII: CONCLUSIONES TÉCNICAS Y RECOMENDACIONES 67
7.1 Matriz objetivo-resultado-conclusión-recomendación 67
7.2 Conclusiones técnicas 68
7.3 Recomendaciones 69
CAPÍTULO VIII: RESPONSABILIDAD ÉTICA Y PROFESIONAL 70
8.1 Tratamiento ético, legal y seguro de los datos 70
8.2 Impactos de las soluciones 71

8.3 Compromiso profesional 71
REFERENCIAS BIBLIOGRÁFICAS 72
ANEXOS Y MANIFIESTO DE EVIDENCIAS 73

RESUMEN

Redacte entre 200 y 300 palabras. Incluya problema, objetivo, soluciones BI y Big Data, diseño experimental, dataset, métricas, principales resultados y conclusión técnica.

La tienda minorista en línea objeto de este proyecto no cuenta con un datamart ni con indicadores consolidados de ventas, clientes y productos, por lo que las decisiones comerciales se apoyan en reportes manuales elaborados en hojas de cálculo. El objetivo del proyecto es implementar una solución de Inteligencia de Negocios (BI) sobre el proceso de ventas, que transforme los registros transaccionales en indicadores verificables, evaluando su desempeño mediante un diseño experimental reproducible. La solución se desarrolla sobre el dataset público Online Retail (541,909 registros, diciembre de 2010 a diciembre de 2011; UCI Machine Learning Repository, licencia CC BY 4.0): se diseñó un modelo dimensional en esquema estrella, con una tabla de hechos fac_ventas y dimensiones cliente, producto, país, tiempo y tipo de transacción, implementado en SQL Server, alimentado por un proceso ETL en T-SQL con extracción mediante BULK INSERT, limpieza, transformación y carga de dimensiones y hechos, y consumido por un dashboard en Power BI con indicadores de ingresos, cancelaciones, ticket promedio, productos y países. A la fecha de este informe, la extracción y la carga del esquema estrella se ejecutaron exitosamente sobre el total de 541,909 registros del dataset de origen, con reconciliación exacta entre el archivo y la tabla de staging; el dashboard de Power BI con esos indicadores ya está implementado y conectado al datamart (ver 3.4.4), y el repositorio del proyecto ya está estructurado y publicado (ver 5.1). El curso contempla además un componente de Big Data sobre volúmenes de datos de mayor escala, que se incorporará al proyecto cuando el sílabo cubra esa unidad. Se concluye, de forma preliminar, que un enfoque

ETL clásico en T-SQL resulta adecuado para el volumen y la complejidad del proceso de ventas analizado.

Palabras clave: Inteligencia de Negocios, esquema estrella, ETL, SQL Server e indicadores de negocio.

ABSTRACT

Traduzca fielmente el resumen y las palabras clave al inglés.

The online retail store addressed in this project has no datamart or consolidated sales, customer and product indicators, so commercial decisions currently rely on manual spreadsheet reports. The project aims to implement a Business Intelligence (BI) solution over the sales process, transforming transactional records into verifiable business indicators, evaluated through a reproducible experimental design. The solution is built on the public Online Retail dataset (541,909 records, December 2010 to December 2011; UCI Machine Learning Repository, CC BY 4.0 license): a star-schema dimensional model was designed, with a fac_ventas fact table and customer, product, country, time and transaction-type dimensions, implemented in SQL Server and fed by a T-SQL ETL process with BULK INSERT extraction, cleansing, transformation and dimension/fact loading, consumed by a Power BI dashboard with revenue, cancellation, average-ticket, product and country indicators. As of this report, the extraction and loading of the star schema has been executed successfully over the full 541,909 source records, with an exact reconciliation between the source file and the staging table; the Power BI dashboard and the project repository are still under development. The course also includes a Big Data component over larger-scale data, which will be added to the project once the syllabus covers that unit. A preliminary conclusion is that a classic T-SQL ETL approach is adequate for the volume and complexity of the sales process analyzed.

Keywords: Business Intelligence, star schema, ETL, SQL Server and business indicators.

CAPÍTULO I: CONTEXTO, PROBLEMA Y OBJETIVOS

1.1 Contexto y necesidad empresarial

La organización objeto de este proyecto es una tienda minorista en línea ("online retail"), con sede y registro en el Reino Unido, dedicada a la venta de artículos de regalo y decoración para todo tipo de ocasiones. Su cartera de clientes combina consumidores finales y comercios mayoristas ubicados en el Reino Unido y en más de una treintena de países de Europa y otras regiones, quienes realizan sus pedidos a través de la plataforma de comercio electrónico de la empresa.

Actualmente, cada pedido se registra de forma transaccional (una factura o InvoiceNo por operación, con una o varias líneas de producto identificadas por StockCode), pero la empresa no cuenta con un datamart ni con indicadores consolidados que integren esta información para la toma de decisiones. Las áreas comercial, de marketing y de atención al cliente dependen de reportes manuales elaborados en hojas de cálculo, lo que dificulta identificar de forma oportuna qué productos y clientes generan mayor valor, cómo varía la demanda por país y temporada, y qué clientes presentan riesgo de abandono ("churn").

Como línea base cuantitativa se dispone de un registro histórico de 541,909 transacciones realizadas entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011 (Chen, 2015). El detalle del número de clientes y países activos en dicho periodo se documentará con cifras verificadas durante la validación del dataset (Capítulo VI), a fin de sustentar con precisión el diagnóstico presentado en este capítulo.

Frente a este escenario, la empresa requiere transitar de un enfoque reactivo y fragmentado de análisis de datos hacia una solución de Inteligencia de Negocios que consolide la información transaccional en un modelo dimensional confiable, preservando en todo momento el anonimato de los clientes. El sílabo del curso contempla además un componente de Big Data sobre volúmenes de datos de mayor escala; su alcance y la herramienta a emplear se

definirán más adelante, cuando el curso cubra esa unidad, y se incorporarán al proyecto en ese momento.

1.2 Formulación del problema de ingeniería

El problema de ingeniería consiste en que la empresa no cuenta con una arquitectura de datos que permita transformar sus registros transaccionales de ventas en información confiable y oportuna para la toma de decisiones comerciales. Las causas principales son: (a) ausencia de un modelo dimensional y de un proceso ETL/ELT documentado que integre y depure los datos de ventas; y (b) inexistencia de indicadores estandarizados (KPI) de ventas, clientes y productos.

Como consecuencia, las decisiones de marketing y de gestión comercial (a qué clientes dirigir campañas de retención, qué productos priorizar en inventario, en qué mercados enfocar los esfuerzos comerciales) se toman con información incompleta o desactualizada, generando un uso ineficiente de los recursos comerciales y un riesgo de pérdida de clientes valiosos sin que la empresa lo detecte a tiempo.

El problema requiere una solución de Inteligencia de Negocios porque exige consolidar datos históricos en un modelo dimensional (esquema estrella) que soporte análisis OLAP multidimensional, por producto, cliente, tiempo y país, y la construcción de indicadores accionables mediante un dashboard. El componente de Big Data complementa esta solución con una segmentación de clientes de tipo RFM (Recencia, Frecuencia, Monto) sobre un volumen de datos mayor al de la solución BI; su diseño conceptual se desarrolla en la sección 3.5, y su implementación con herramientas de procesamiento distribuido (Apache Spark) se realiza cuando el sílabo del curso cubre la Unidad III, en una etapa posterior del proyecto.

Entre las restricciones del problema se encuentran: no utilizar identidad real de los clientes (solo el identificador anonimizado CustomerID), trabajar únicamente con datos históricos públicos y reproducibles, y limitar la infraestructura a recursos de cómputo académico (entorno local o clúster de prueba).

1.3 Objetivos

Objetivo general: Implementar una solución de Inteligencia de Negocios sobre el proceso de ventas de una tienda minorista en línea (dataset Online Retail), que transforme datos transaccionales en indicadores de negocio verificables, evaluando su desempeño mediante un diseño experimental reproducible. El proyecto incorporará un componente de Big Data en una etapa posterior, cuando el curso proporcione suficiente información.

Objetivos específicos:

1. (BI) Diseñar e implementar un modelo dimensional (esquema estrella) y un proceso ETL/ELT sobre el dataset Online Retail, que alimente un datamart y un dashboard con indicadores de ventas, productos, clientes y países.

2. (Big Data) Diseñar un componente de Big Data que complemente la solución de Inteligencia de Negocios mediante una segmentación de clientes de tipo RFM (Recencia, Frecuencia, Monto) sobre un volumen de datos mayor, utilizando herramientas de procesamiento distribuido (Apache Spark); la implementación se realiza cuando el sílabo del curso cubra la Unidad III de procesamiento distribuido.

3. (Experimentación) Diseñar y ejecutar un experimento reproducible sobre la solución BI, midiendo variables de rendimiento y calidad de los resultados de negocio; se ampliará a una comparación con la solución Big Data cuando esta se incorpore al proyecto.

4. (Ética y gobierno de datos) Garantizar, a lo largo del proyecto, el uso responsable de datos públicos y anonimizados, documentando su procedencia, licencia y limitaciones de privacidad.

1.4 Alcance, restricciones y supuestos

Alcance: el proyecto abarca el proceso de ventas en línea de la empresa (registro de pedidos, productos, clientes y países), desde la ingesta del dataset Online Retail hasta la entrega

de un dashboard BI funcional. Se excluyen del alcance los procesos de logística y despacho físico, atención postventa, pasarelas de pago y cualquier sistema operacional de la empresa distinto al registro de ventas, dado que dicha información no forma parte del dataset utilizado. El componente de Big Data se incorporará al alcance cuando el curso cubra esa unidad.

Restricciones: técnicas, uso de herramientas de código abierto y de acceso académico (motor relacional, herramienta de visualización); de tiempo, 16 semanas correspondientes al ciclo académico 2026-2 según el sílabo del curso; de privacidad, no se dispone de datos personales identificables (nombre, correo, documento de identidad) de los clientes, solo de un identificador numérico anónimo (CustomerID); de infraestructura, procesamiento en entorno local, sin presupuesto para infraestructura en la nube de pago.

Supuestos: se asume que el dataset Online Retail es representativo del comportamiento de una tienda minorista en línea de características similares a las descritas en el contexto del proyecto, aun cuando corresponde a una empresa real y anonimizada distinta de la organización analizada.

1.5 Stakeholders y criterios de éxito

STAKEHOLDER	NECESIDAD / DECISIÓN	CRITERIO DE ÉXITO	EVIDENCIA
Gerencia comercial	Identificar qué clientes y productos generan mayor valor para orientar campañas y negociaciones con proveedores	Dashboard BI publicado con al menos 5 indicadores de ventas y clientes, validado por el docente	E-07

STAKEHOLDER	NECESIDAD / DECISIÓN	CRITERIO DE ÉXITO	EVIDENCIA
Área de marketing	Identificar clientes frecuentes y de mayor valor a partir de los indicadores del dashboard BI, para dirigir campañas de retención.	Dashboard BI con indicadores de clientes activos y tasa de recompra, validado por el docente.	E-07
Equipo de datos / TI (equipo del proyecto)	Contar con un modelo de datos y un proceso ETL reproducible para la solución BI, sin duplicar el esfuerzo de mantenimiento.	Repositorio versionado con documentación y scripts ETL ejecutables de extremo a extremo.	E-05 / E-06

1.6 Fuentes, gobierno y ética de los datos

Los datos utilizados provienen del dataset público "Online Retail" del repositorio UCI Machine Learning Repository, donado por el Dr. Daqing Chen (London South Bank University) bajo licencia Creative Commons Attribution 4.0 International (CC BY 4.0), que permite su uso, adaptación y redistribución citando la fuente (Chen, 2015). El dataset contiene 541,909 registros correspondientes al periodo 01/12/2010 al 09/12/2011.

El dataset no contiene datos personales identificables: no incluye nombre, dirección, correo electrónico ni documento de identidad de los clientes. El campo CustomerID es un identificador numérico asignado por el propietario original del dataset con fines de investigación, por lo que no permite, por sí mismo, identificar a una persona natural. En

consecuencia, no se requiere un proceso adicional de anonimización por parte del equipo, aunque sí se mantendrá como buena práctica tratar el CustomerID exclusivamente como clave de agrupación estadística y no como dato personal.

En cuanto a calidad, el dataset presenta registros con cantidades negativas (devoluciones) y valores vacíos de CustomerID en un porcentaje de filas, aspectos que serán tratados explícitamente durante el proceso ETL/ELT (Capítulo III) y documentados en el perfilado de datos (Capítulo VI). El acceso a los datos y al repositorio del proyecto se limitará a los integrantes del equipo y al docente del curso, sin publicación del dataset fuera de los repositorios académicos autorizados. El principal riesgo de sesgo identificado es que el dataset corresponde a una única empresa del Reino Unido especializada en artículos de regalo, por lo que los indicadores obtenidos no son necesariamente generalizables a otros giros de negocio o mercados geográficos.

CAPÍTULO II: ANTECEDENTES Y FUNDAMENTOS

2.1 Antecedentes

Antecedente 1. Chen et al. (2012) abordaron el problema de que las empresas minoristas en línea, pese a acumular grandes volúmenes de transacciones, carecen de mecanismos sistemáticos para identificar qué clientes son más valiosos y merecen esfuerzos de retención diferenciados. Los autores aplicaron el modelo RFM (Recencia, Frecuencia, Monto) sobre datos reales de una tienda minorista en línea del Reino Unido, el mismo dataset Online Retail empleado en este proyecto, combinando reglas RFM con técnicas de agrupamiento para segmentar la base de clientes. Las métricas empleadas fueron los tres indicadores RFM por cliente y la calidad de los grupos resultantes. Los resultados mostraron que era posible distinguir grupos de clientes claramente diferenciados por su comportamiento de compra. Este antecedente confirma que el dataset Online Retail ya ha sido validado académicamente para análisis de

clientes, y respalda la técnica RFM como una opción a evaluar si el proyecto incorpora más adelante un componente de Big Data.

Antecedente 2. Coronel-Alayo et al. (2021) enfrentaron el problema de que los productores agrícolas de la provincia de Otuzco (La Libertad, Perú) tomaban decisiones basadas en información no oficial o en su propia experiencia, sin acceso oportuno a datos consolidados. Implementaron un sistema de inteligencia de negocios siguiendo la metodología Scrum, utilizando datos de la Gerencia Regional de Agricultura de La Libertad y encuestas a productores. Como métricas evaluaron el tiempo de respuesta a consultas y el nivel de aceptación de los usuarios. Los resultados mostraron una reducción del tiempo de respuesta de 8 horas a 15 minutos y una ampliación del alcance de la información del 7% al 71%. Este antecedente aporta evidencia de que una solución BI bien diseñada puede transformar radicalmente los tiempos de generación de reportes, meta que también persigue el dashboard de ventas de este proyecto.

Antecedente 3. Risco-Ramos et al. (2023) trabajaron el problema de cómo las pequeñas y medianas empresas (PYMES) pueden aplicar minería de datos dentro de plataformas de inteligencia de negocios sin incurrir en costos elevados de infraestructura. Aplicaron la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining) utilizando Power BI como plataforma de BI, en un caso de estudio de pronóstico de producción de una PYME de generación hidroeléctrica. Las métricas evaluadas fueron la precisión del pronóstico y la factibilidad de implementación con hardware y software accesibles. Los resultados confirmaron que la combinación de CRISP-DM y Power BI genera mejores resultados que las prácticas convencionales de la empresa. Este antecedente valida a Power BI como herramienta de BI adecuada para PYMES y respalda el uso de una metodología estructurada de minería de datos en el proceso ETL/OLAP de la solución BI de este proyecto.

Antecedente 4. Vargas Rios et al. (2025) atendieron el problema de que las empresas exportadoras de La Libertad, Perú, carecían de herramientas que centralizaran y presentaran información clave para la toma de decisiones, en un contexto de mayor competencia tras la puesta en marcha del Puerto de Chancay. Implementaron un datamart, un almacén de datos de alcance acotado, como componente central de una estrategia de inteligencia de negocios, con un diseño cuasiexperimental para medir el impacto en la eficiencia, confiabilidad y precisión de la toma de decisiones. Los resultados mostraron mejoras significativas en las tres dimensiones evaluadas. Este antecedente es relevante porque valida, en el contexto empresarial peruano, el enfoque de almacén de datos acotado a un solo proceso de negocio que se sigue en el modelo dimensional de este proyecto (sección 3.4.2).

2.2 Fundamentos de Inteligencia de Negocios

La integración de datos consiste en consolidar información proveniente de una o más fuentes heterogéneas (en este proyecto, el archivo transaccional del dataset Online Retail) en un repositorio único y coherente que sirva de base para el análisis. Este proceso se ejecuta mediante un flujo ETL (Extract, Transform, Load) o ELT (Extract, Load, Transform): en el enfoque ETL, los datos se extraen del origen, se transforman (limpieza, estandarización, cálculo de nuevas columnas) fuera del motor de destino y luego se cargan ya depurados; en el enfoque ELT, los datos se cargan primero en el destino y las transformaciones se ejecutan dentro del propio motor. En este proyecto se optó por un enfoque ETL clásico implementado con procedimientos T-SQL, dado que el volumen del dataset (541,909 registros) es manejable dentro de SQL Server sin requerir la carga previa de datos crudos a gran escala.

El **modelado dimensional** es la técnica de diseño de bases de datos analíticas propuesta por Kimball y Ross (2013), que organiza los datos en tablas de hechos (que almacenan las métricas del negocio, como el importe de una venta) y tablas de dimensiones (que almacenan los atributos descriptivos, como cliente, producto, fecha y país). El esquema resultante, llamado

esquema estrella, facilita las consultas analíticas al reducir el número de uniones necesarias. Esta es la estructura que se aplicará en el proyecto: un hecho de venta (por línea de factura) con las dimensiones Cliente, Producto, Fecha y País. Frente al enfoque bottom-up de Kimball (construir primero data marts departamentales y luego integrarlos), existe el enfoque top-down de Inmon (2005), que propone construir primero un almacén de datos corporativo normalizado y derivar de él los data marts. Dado el alcance acotado de este proyecto (un solo proceso de negocio: ventas), se adoptará el enfoque de Kimball por ser más ágil para un data mart de alcance limitado.

El almacén de datos (data warehouse) es el repositorio central, orientado a temas, integrado, variante en el tiempo y no volátil (Inmon, 2005), donde se almacenan los datos ya transformados; un data mart es una versión reducida y orientada a un área específica del negocio (en este caso, ventas), concepto que en la Actividad 07 del curso se trabajó como ejercicio de clase y que aquí corresponde al propio entregable del proyecto: lo que se implementa en dw_onlineretail es un datamart de ventas, de alcance acotado a un solo proceso de negocio, no un almacén de datos corporativo; el nombre de la base (dw_onlineretail) se mantiene por la convención de nombres ya definida en el curso, aunque el entregable es técnicamente un datamart. El análisis OLAP (Online Analytical Processing) permite explorar estos datos desde múltiples dimensiones simultáneamente (por ejemplo, ventas por producto, país y mes), mediante operaciones como drill-down (profundizar el nivel de detalle), roll-up (agregar a un nivel superior), slice y dice (filtrar y rotar dimensiones). Finalmente, los indicadores (KPI) son métricas de negocio calculadas sobre el modelo dimensional (por ejemplo, ingreso total, ticket promedio, tasa de recompra) que se presentan mediante visualización de datos, en este proyecto mediante dashboards en Power BI, con el objetivo de apoyar decisiones concretas del negocio.

2.3 Fundamentos de Big Data

Las V de Big Data. El Big Data se caracteriza habitualmente por un conjunto de "V": Volumen (cantidad de datos, que supera lo manejable por un único servidor relacional), Velocidad (la rapidez con la que los datos se generan y deben procesarse, ya sea por lotes o en tiempo real), Variedad (datos estructurados, semiestructurados y no estructurados conviviendo en una misma solución), Veracidad (confiabilidad y calidad de los datos de origen) y Valor (el resultado de negocio que justifica procesar ese volumen). El dataset Online Retail, con 541,909 registros estructurados, es manejable con un enfoque relacional clásico (Capítulo III); el componente de Big Data de este proyecto se justificará, cuando se diseñe (sección 3.5), sobre un volumen mayor o un requisito de procesamiento distribuido que supere ese enfoque.

Procesamiento distribuido. A diferencia de un motor de base de datos relacional, que procesa los datos en un único servidor, el procesamiento distribuido reparte los datos y el cálculo entre varios nodos de un clúster, de modo que el tiempo de procesamiento escale agregando más nodos en lugar de más recursos a una sola máquina (escalabilidad horizontal). Apache Hadoop fue el primer ecosistema ampliamente adoptado para esto, mediante el sistema de archivos distribuido HDFS y el modelo de programación MapReduce; Apache Spark surgió después como una alternativa más rápida, al procesar en memoria en lugar de escribir resultados intermedios a disco en cada paso.

Apache Spark: RDD, DataFrames y SparkSQL. Spark organiza el cálculo distribuido en tres niveles de abstracción, de menor a mayor nivel: los RDD (Resilient Distributed Datasets) son colecciones de datos particionadas entre los nodos del clúster, tolerantes a fallos porque Spark puede reconstruir una partición perdida a partir de las operaciones que la generaron; los DataFrames agregan una estructura tabular (columnas con nombre y tipo) sobre los RDD, de forma similar a una tabla de SQL Server o un data frame de pandas; y SparkSQL permite consultar esos DataFrames con sentencias SQL estándar, lo que facilita reutilizar el conocimiento de T-SQL ya aplicado en la solución BI (Capítulo III). Esta es la herramienta que el sílabo del curso introduce en la Unidad III (semanas 11 a 15: gestión de

datos con Spark, operaciones sobre RDD en clúster, SparkSQL y DataFrames, análisis y visualización de datos con Spark).

Relación con la solución BI de este proyecto. El componente de Big Data no reemplaza a la solución de Inteligencia de Negocios: la complementa sobre el mismo dominio de negocio (ventas de la tienda en línea), con una pregunta que el modelo dimensional por sí solo no resuelve bien, por ejemplo una segmentación de clientes (recencia, frecuencia, monto) calculada sobre un volumen de datos mayor al de Online Retail. El diseño concreto de este componente (arquitectura, requisitos y alcance) se desarrolla en la sección 3.5, y su ejecución con Spark se realizará cuando el curso cubra esa unidad.

2.4 Tecnologías, estándares y trabajos relacionados

Para la solución BI se evaluaron dos alternativas de motor de base de datos: un motor relacional (SQL Server) y una base de datos NoSQL orientada a documentos. Se optó por SQL Server porque el modelo de datos del proceso de ventas es naturalmente relacional (facturas, líneas de detalle, clientes, productos) y porque el curso exige el uso de T-SQL en la Unidad I del sílabo; además, SQL Server ofrece integración nativa con Power BI mediante conectores certificados. La versión de referencia es SQL Server 2022, ampliamente utilizada en entornos productivos y educativos, siendo también viable emplear SQL Server 2025 (disponible desde noviembre de 2025) si el laboratorio del curso lo tuviera instalado.

Para la capa de visualización se seleccionó Microsoft Power BI frente a alternativas como Tableau, por su integración directa con SQL Server, su edición gratuita para uso individual (Power BI Desktop) y por ser la herramienta empleada en antecedentes académicos comparables sobre PYMES peruanas (Risco-Ramos et al., 2023).

Los criterios de selección aplicados fueron: rendimiento (evidencia empírica de benchmarks académicos), escalabilidad (capacidad de crecer con el volumen de datos sin rediseño), interoperabilidad (integración entre el motor relacional y Power BI), seguridad

(control de acceso y tratamiento del CustomerID como dato sensible aunque anonimizado), mantenibilidad (tecnologías ampliamente documentadas y con comunidad activa) y costo (todas las herramientas seleccionadas cuentan con una edición gratuita o de uso académico).

CAPÍTULO III: DISEÑO DE INGENIERÍA DE LAS SOLUCIONES

3.1 Requerimientos funcionales y no funcionales

Los requisitos se identifican con un código para trazarlos desde el problema del Capítulo I hasta la implementación y las pruebas (Capítulo V). El prefijo RF-BI corresponde a los requisitos funcionales de la solución de Inteligencia de Negocios y RNF a los no funcionales. Los requisitos de la solución Big Data se agregarán cuando esa solución se defina (ver 2.3).

Tabla 3.1. Requisitos funcionales, Solución de Inteligencia de Negocios

Código	Requerimiento
RF-BI-01	Cargar el dataset Online Retail completo en una tabla de staging, sin alterar los datos originales.
RF-BI-02	Aplicar reglas de limpieza documentadas y separar los registros no válidos de los cargados al modelo.
RF-BI-03	Poblar un modelo dimensional (esquema estrella) con una tabla de hechos de

	ventas y las dimensiones cliente, producto, país, tiempo y tipo de transacción.
RF-BI-04	Calcular los indicadores (KPI) definidos en 3.4.1 a partir del modelo dimensional.
RF-BI-05	Mostrar un dashboard con filtros por fecha, país y producto.
RF-BI-06	Separar las ventas de las cancelaciones (facturas con prefijo "C"), de modo que los ingresos no se distorsionen.
RF-BI-07	Automatizar la extracción y la carga mediante objetos de base de datos repetibles (SQL dinámico parametrizado para el BULK INSERT y reinicio de identidades con DBCC CHECKIDENT en cada reproceso).

Tabla 3.2. Requisitos no funcionales

Código	Categoría	Requerimiento
RNF-01	Calidad	La carga debe conciliar el 100% de las filas entre el origen, lo cargado y lo descartado.

RNF-02	Calidad	El proceso de limpieza y carga debe ser repetible: dos ejecuciones sobre los mismos datos deben producir el mismo resultado.
RNF-03	Tiempo de respuesta	Cada visual del dashboard debe responder en menos de 5 segundos con los filtros habituales.
RNF-04	Rendimiento	El proceso completo de ETL debe ejecutarse en menos de 60 segundos (línea base medida: 4 segundos, ejecución del 09/10/2026 sobre 541,909 filas; ver 6.2).
RNF-05	Escalabilidad	El modelo dimensional debe soportar el crecimiento normal del volumen de ventas sin rediseño.
RNF-06	Seguridad	El sistema debe usar únicamente datos anónimos, con acceso restringido por

		roles y sin credenciales escritas en los scripts.
RNF-07	Disponibilidad	El modelo de datos debe contar con un respaldo restaurable, sin exigir alta disponibilidad por tratarse de un entorno académico.
RNF-08	Trazabilidad	Cada indicador y cada visual del dashboard debe tener identificada su fuente de datos dentro del modelo.

3.2 Alternativas y decisiones de arquitectura

Se evalúan alternativas para las decisiones de arquitectura de la solución de Inteligencia de Negocios; las comparaciones tecnológicas de fondo ya se desarrollaron en la sección 2.4, por lo que aquí solo se resume la decisión y su criterio.

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
D1. Almacenamiento analítico: SQL Server (modelo relacional) frente a MongoDB (NoSQL documental)	Integración con Power BI (alta); contenido del sílabo, Unidades I y II (alta); naturaleza relacional de facturas y líneas de detalle (alta)	SQL Server: SQL estándar y T-SQL para ETL y automatización; conector nativo con Power BI.	SQL Server escala de forma vertical; MongoDB facilita el esquema flexible pero dificulta las agregaciones analíticas y la conexión directa con herramientas BI.	SELECCIONADA: SQL Server.
D2. Visualización: Power BI frente a Tableau	Integración con SQL Server (alta); costo (alta); uso en antecedentes académicos sobre PYMES (media)	Conector nativo a SQL Server; versión Desktop gratuita; modelo semántico y medidas (DAX).	Power BI Desktop solo corre en Windows; publicar en la nube requiere licencia. Tableau tiene licencia de pago y no se usa en el curso.	SELECCIONADA: Power BI.

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
D3. Metodología de modelado dimensional: Kimball (ascendente) frente a Inmon (descendente)	Rapidez de entrega (alta); adecuación a un solo proceso de negocio, ventas (alta)	Kimball entrega un datamart de ventas con esquema estrella, de consulta directa y rápido de implementar.	Inmon exige construir primero un almacén corporativo normalizado, lo que resulta excesivo para un solo proceso de negocio en el plazo del curso.	SELECCIONADA: Kimball y Ross (2013).

3.3 Arquitectura integrada y flujo de datos

La arquitectura de la solución de Inteligencia de Negocios lleva el dataset Online Retail desde el archivo de origen hasta un dashboard, pasando por staging, un proceso ETL en T-SQL y un datamart con esquema estrella en SQL Server; esta arquitectura se encuentra implementada y verificada a la fecha de este informe (ver 3.4.3 y Capítulo VI). El proyecto incorporará una ruta de Big Data cuando el curso cubra esa unidad (sección 2.3).

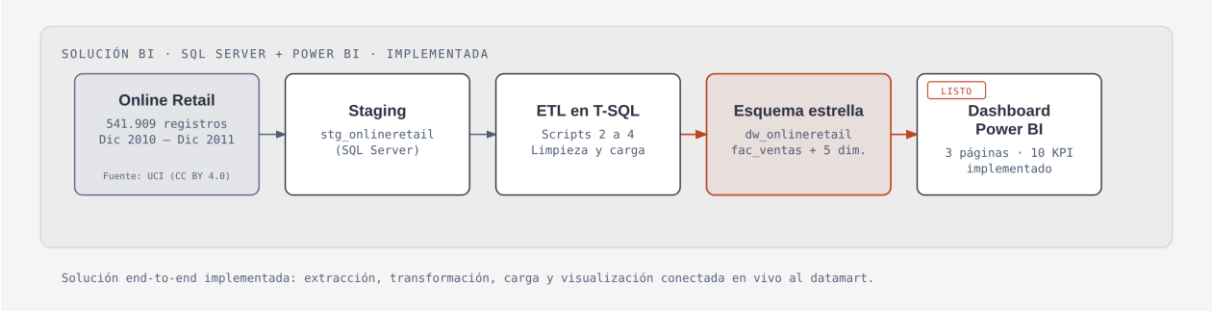


Figura 1. Arquitectura de la solución de Inteligencia de Negocios (Online Retail).

Componentes y tecnologías. La Tabla 3.3 resume cada componente de la arquitectura, con su tecnología, su función, su entrada y su salida.

Tabla 3.3. Componentes, tecnologías e interfaces

Componente	Tecnología	Función	Entrada	Salida
Fuente	Archivo Online Retail (.xlsx), exportado a texto delimitado por tabulaciones	Datos transaccionales de ventas	Descarga desde UCI (CC BY 4.0)	Archivo .txt
Staging	SQL Server, tabla stg_onlineretail	Copia fiel de los datos crudos	BULK INSERT del archivo .txt	Tabla de staging (541,909 filas)
ETL	T-SQL (Script 2, proceso ETL completo)	Limpieza, transformación y carga	Tabla de staging	Dimensiones y tabla de hechos fac_ventas
Almacén de datos	SQL Server, esquema estrella dw_onlineretail	Almacén dimensional de ventas	Cargas del ETL	Consultas del dashboard
Dashboard	Power BI Desktop 2.158.1304.0 (Microsoft Store, instalado;	Indicadores, filtros, análisis OLAP	Conexión Windows Authentication al datamart	Reportes para usuarios

	archivo .pbix en construcción)			

3.4 Diseño de la solución de Inteligencia de Negocios

3.4.1 Requisitos, usuarios e indicadores

Las preguntas de negocio provienen del problema planteado en el Capítulo I: no se sabe qué productos y clientes generan más valor y no se detecta oportunamente el abandono. Las metas de la Tabla 3.4 corresponden a la línea base calculada sobre los datos ya cargados en dw_onlineretail.

Tabla 3.4. Preguntas de negocio, usuarios e indicadores (KPI)

ID	Pregunta / decisión	Usuario	KPI y fórmula	Granularidad	Frecuencia	Fuente	Meta
K1	¿Cuánto se vende? Evaluar el desempeño global.	Gerencia comercial	Ingresos brutos = SUMA(cantidadVendida x precioUnitarioVenta) en filas de venta (tipo "V")	Día, mes, país, producto	Mensual	fac_ventas	Crecer 10 % sobre el promedio mensual de la línea base: alcanzar al menos GBP (libras esterlinas) 902.500 vendidos por mes (línea base: GBP 10.666.684,54 totales en 13 meses, dic. 2010 a dic. 2011, promedio GBP

							820.514/mes).
K2	¿Cuánto se cancela? Detectar problemas de operación.	Operaciones	Monto cancelado = SUMA(cantidadVendida x precioUnitarioVenta) en filas de tipo "C"	Mes, producto	Mensual	fac_ventas	Reducir el monto cancelado mensual por debajo de GBP 58.600 (línea base: promedio GBP 68.986/mes), una baja del 15 %.
K3	¿Cuál es el ingreso real? Medir el resultado sin distorsión.	Gerencia comercial	Ingresos netos = K1 menos K2	Mes, país	Mensual	fac_ventas	Crecer 10 % sobre el promedio mensual de ingresos netos: superar GBP 826.700 por mes (línea base: promedio GBP 751.529/mes).
K4	¿Cuánto gasta el cliente por compra? Definir promociones.	Marketing	Ticket promedio = ingresos brutos / número de facturas distintas no canceladas	Mes, país	Mensual	fac_ventas	Elevar el ticket promedio a GBP 550 por factura (línea base: GBP 534,40).
K5	¿Qué proporción de facturas se cancela? Controlar la	Operaciones	Tasa de cancelación = facturas con tipo "C" / facturas totales	Mes, país	Mensual	fac_ventas, dim_tipotransaccion	Bajar la tasa de cancelación a 14 % o menos (línea

	calidad del servicio.						base: 16,12 %).
K 6	¿Qué productos priorizar? Decidir catálogo y reposición.	Operaciones y marketing	Top 10 productos por ingresos y por unidades vendidas	Producto, mes	Mensual	fac_ventas, dim_producto	Sostener en el top 10 a los productos líderes actuales (ver detalle en el script del equipo) y alertar si alguno cae más de 15 % en ingresos de un mes a otro.
K 7	¿Cuántos clientes compran? Medir la base activa.	Marketing	Clientes activos = id_cliente distintos con al menos una venta en el periodo	Mes	Mensual	fac_ventas, dim_cliente	Crecer 5 % la base de clientes activos respecto a la línea base (4.371 clientes en el período cargado).
K 8	¿Cuántos clientes vuelven a comprar? Evaluar fidelidad.	Marketing	Tasa de recompra = clientes con 2 o más facturas / clientes con al menos una factura	Periodo	Trimestra l	fac_ventas, dim_cliente	Elevar la tasa de recompra a 72 % o más (línea base: 69,98 %).
K 9	¿Dónde se vende más? Definir mercados prioritarios.	Gerencia comercial	Ingresos por país = K1 agrupado por país	País, mes	Mensual	fac_ventas, dim_pais	Reducir la concentració n de Reino Unido de 84,6 % a 80 % de los ingresos, creciendo la

							participación conjunta de Países Bajos, Irlanda (EIRE), Alemania y Francia.
K 10	¿Qué clientes están en riesgo de abandono? Priorizar campañas de retención antes de perderlos.	Marketing	Recencia por cliente = días entre la fecha de referencia (última fecha del dataset) y la última fecha de compra del cliente; cliente en riesgo si recencia > 90 días.	Cliente	Mensual	fac_ventas, dim_cliente, dim_tiempo	Bajar la tasa de clientes en riesgo de abandono (recencia > 90 días sin comprar) de 33,40 % a 25 % de la base de clientes activos: de 1.449 a cerca de 1.085 clientes en riesgo, mediante campañas de reactivación dirigidas a ese grupo (línea base: 4.338 clientes activos con al menos una venta y 1.449 en riesgo, calculado el 09/10/2026 sobre dw_onlineretail; esta cifra de clientes activos

							difiere levemente de la de K7 porque aquí se cuentan solo los que tienen al menos una venta efectiva, sin incluir a quienes solo registran cancelaciones).

Línea base calculada el 09/10/2026 sobre dw_onlineretail (541.909 filas cargadas, UCI Online Retail), para K1-K10. Evidencia de ejecución y registro de corridas: Capítulo VI. Las metas de la Tabla 3.4 son porcentajes de mejora propuestos por el equipo sobre esa línea base, ajustables según lo acordado con el área de negocio.

3.4.2 Modelo dimensional y datamart

Se aplica la metodología de Kimball (decisión D3, Tabla 3.2) sobre un único proceso de negocio: la venta de productos. El grano de la tabla de hechos fac_ventas es una línea de factura consolidada por producto y precio unitario: cuando un mismo producto aparece más de una vez en la misma factura al mismo precio, esas líneas se agrupan en una sola fila (SUM de cantidadVendida e importeVendido), para no duplicar filas que distorsionen las medidas; numeroFacturaVenta se conserva como atributo degenerado dentro de los hechos, porque sirve para contar facturas pero no tiene atributos propios. Los nombres de las medidas y del atributo degenerado indican a qué se refieren sin depender del nombre de la tabla: cantidadVendida y precioUnitarioVenta por el producto y el precio, importeVendido en la misma forma que cantidadVendida (lo que se vendió en esa línea, no el total de la factura), y numeroFacturaVenta por el número de factura. El esquema físico se implementó en SQL Server siguiendo la convención de nombres del curso (minúsculas, prefijos id_, pk_, dim_, fac_ y stg_) y se verificó cargando el total de 541,909 registros del dataset (Capítulo VI).

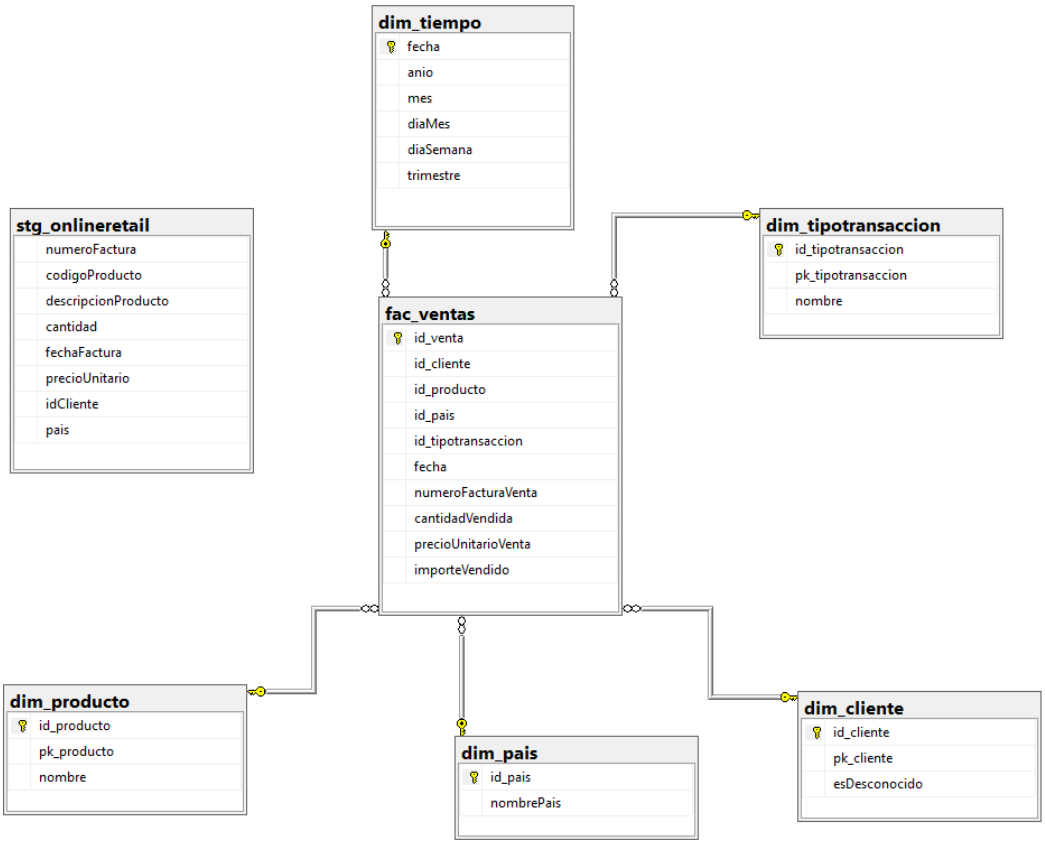


Figura 2. Esquema estrella implementado en SQL Server (base de datos dw_onlineretail).

Tabla 3.5. Matriz de proceso contra dimensiones (matriz bus)

Proceso de negocio	**dim_tiempo**	**dim_cliente**	**dim_producto**	**dim_pais / dim_tipotransaccion**
Venta de productos (línea de factura)	X	X	X	X

Tabla 3.6. Diccionario de datos, tabla de hechos fac_ventas

Atributo	Tipo (SQL Server)	Descripción
id_venta	int, identity, PK	Llave sustituta de la línea de venta.
id_cliente	int, FK a dim_cliente	Cliente asociado a la venta (o cliente "desconocido" si no venía CustomerID).
id_producto	int, FK a dim_producto	Producto vendido.
id_pais	int, FK a dim_pais	País del cliente en la factura.
id_tipotransaccion	int, FK a dim_tipotransaccion	Venta ('V') o cancelación ('C'), según el prefijo de numeroFacturaVenta.
fecha	date, FK a dim_tiempo	Fecha de la factura (sin hora).
numeroFacturaVenta	varchar(10)	Número de factura (InvoiceNo); dimensión degenerada.
cantidadVendida	int	Unidades vendidas en la línea (suma agrupada).
precioUnitarioVenta	money	Precio unitario del producto (UnitPrice).
importeVendido	money	cantidadVendida multiplicado por precioUnitarioVenta.

Tabla 3.7. Diccionario de datos, dimensiones

Dimensión	Atributos	Regla	Origen (columna del dataset)
dim_cliente	id_cliente (PK), pk_cliente, esDesconocido	Un registro especial con esDesconocido = 1 agrupa las ventas sin CustomerID.	CustomerID
dim_producto	id_producto (PK), pk_producto, nombre	nombre se toma como la descripción más repetida por código de producto.	StockCode, Description
dim_pais	id_pais (PK), nombrePais	Sin jerarquía.	Country
dim_tiempo	fecha (PK), anio, mes, diaMes, diaSemana, trimestre	Tabla calendario generada día por día entre la fecha mínima y máxima del staging.	InvoiceDate
dim_tipotransaccion	id_tipotransaccion (PK), pk_tipotransaccion, nombre	Dos filas fijas: 'V' = Venta, 'C' = Cancelación, según el prefijo de InvoiceNo.	InvoiceNo (prefijo)

Historial de cambios (dimensiones de variación lenta). dim_cliente, dim_producto y dim_pais usan el tratamiento tipo 1 (sobrescribir el valor): el dataset no registra cambios de atributos en el tiempo y no hay una pregunta de negocio que requiera conservar versiones anteriores. dim_tiempo es estática.

Nota sobre fechaFactura en staging. La columna fechaFactura de la tabla de staging stg_onlineretail se definió como varchar(30) en lugar de datetime, porque una parte de las filas

del archivo exportado desde Excel llegó como número de serie de fecha en vez de texto con formato; esta decisión de diseño y su causa se documentan en 3.4.3.

3.4.3 Procesos ETL/ELT y calidad

El proceso ETL se implementó en dos scripts T-SQL ejecutados en SQL Server Management Studio (SSMS) 20, siguiendo el orden: Script 1, creación de la base de datos y las siete tablas (dimensiones, staging y fac_ventas); Script 2, proceso ETL completo en cuatro pasos internos -reseteo de tablas, extracción a staging, carga de las dimensiones y carga de la tabla de hechos-, más la verificación final. El proceso se ejecutó y verificó sobre el total del dataset Online Retail.

Tabla 3.8. Etapas del proceso ETL implementado

Etapa	Qué se hace	Objeto / script	Control
1. Extracción	Importar el archivo exportado desde Excel (texto delimitado por tabulaciones) a la tabla de staging mediante BULK INSERT con SQL dinámico.	Script 2 (Paso 2), tabla stg_onlineretail	SELECT COUNT(*) FROM stg_onlineretail = 541,909 (conteo verificado, igual al archivo de origen).
2. Reseteo	Antes de cada reproceso, se vacían fac_ventas y las dimensiones y se reinician sus identidades con DBCC CHECKIDENT, para que la carga sea repetible (RNF-02).	Script 2 (Paso 1)	Conteo de filas en 0 antes de recargar.
3. Transformación y carga de dimensiones	A partir de los valores distintos del	Script 2 (Paso 3)	Revisión del contenido de cada

	staging se pueblan dim_cliente, dim_producto, dim_pais y dim_tipotransaccion; dim_tiempo se genera con un bucle día por día entre la fecha mínima y máxima del staging.		dimensión (SELECT * / TOP 10).
4. Carga de hechos	INSERT...SELECT que une el staging con cada dimensión por su llave de negocio, agrupando por cliente, producto, país, tipo de transacción, fecha y número de factura, y calculando cantidadVendida e importeVendido.	Script 2 (Paso 4), tabla fac_ventas	Sin llaves huérfanas; filas cargadas coherentes con el staging filtrado (precioUnitario > 0).
5. Control de errores	Durante la ejecución real del Script 2 se presentaron y corrigieron dos errores de carga (ver nota de depuración más abajo).	BULK INSERT con SQL dinámico	Mensajes de error de SSMS revisados y corregidos antes de continuar.
6. Reconciliación	Comparación de conteos entre el archivo de origen y la tabla de staging.	SELECT COUNT(*) AS totalStaging FROM stg_onlineretail	Resultado obtenido: totalStaging = 541,909, igual al origen (100% conciliado).

Depuración real durante la ejecución (evidencia de control de errores). Al ejecutar el Script 2 por primera vez, con el archivo exportado como CSV separado por comas, SQL Server devolvió errores de conversión de datos en la columna "cantidad": la columna

descripcionProducto del dataset contiene texto con comas, lo que desplazaba las columnas del archivo. La corrección fue exportar el archivo desde Excel como "Texto (delimitado por tabulaciones) (*.txt)" y cambiar el FIELDTERMINATOR del BULK INSERT de coma a CHAR(9) (tabulador). Al reintentar, apareció un segundo error, esta vez de conversión en la columna "fechaFactura": una parte de las fechas llegó como número de serie de Excel en vez de texto con formato de fecha, lo que una columna datetime no acepta directamente. La corrección fue redefinir fechaFactura como varchar(30) en el staging y resolver la fecha real en cada consulta posterior con COALESCE(TRY_CONVERT(date, fechaFactura, 103), CASE WHEN ISNUMERIC(fechaFactura) = 1 THEN CAST(DATEADD(DAY, CAST(fechaFactura AS FLOAT), '1899-12-30') AS DATE) END), que interpreta tanto el texto de fecha como el número de serie de Excel (contado desde el 30 de diciembre de 1899). Tras ambas correcciones, la ejecución completa cargó las 541,909 filas sin errores.

Tabla 3.9. Reglas de calidad y limpieza aplicadas

ID	Condición	Tratamiento aplicado
R01	InvoiceNo con prefijo "C" (cancelación)	Se clasifica en dim_tipotransaccion como 'C' y se reporta por separado del importe de ventas (K2, K3).
R02	CustomerID nulo	La fila se conserva en fac_ventas asociada al registro "cliente desconocido" (esDesconocido = 1) de dim_cliente, para no perder ventas.
R03	precioUnitario menor o igual a 0	Se excluye de la carga de fac_ventas (condición WHERE precioUnitario > 0 en el Script 2, Paso 4).
R04	fechaFactura en formato de texto o como número de serie de Excel	Se resuelve con la expresión COALESCE(TRY_CONVERT...) descrita arriba; si ninguna de las

		dos conversiones es válida, la fila se excluye de fac_ventas.
R05	Description repetida o distinta para un mismo StockCode	dim_producto toma la descripción más frecuente por código de producto (MAX agrupado por codigoProducto).

Perfilado cuantitativo. Para cada regla de la Tabla 3.9 se ejecutaron consultas de conteo sobre stg_onlineretail (antes de la limpieza) y sobre fac_ventas o la dimensión correspondiente (después de aplicar la regla). Los resultados se presentan en la Tabla 3.10. En R01 y R02 la diferencia entre el conteo antes y después se explica porque parte de esas filas también cumplía la condición de R03 o R04 (precio nulo o fecha inválida) y por lo tanto fue excluida de fac_ventas antes de llegar a clasificarse o conservarse. El total de stg_onlineretail (541.909 filas) coincide con el dataset de origen.

Tabla 3.10. Resultados del perfilado cuantitativo (antes y después)

ID	Condición	Filas antes (staging)	Filas después	Diferencia	Observación
R01	Cancelaciones (numeroFactura like 'C%')	9.288	9.218	-70	Se clasifican, no se excluyen; la diferencia son filas que además cumplían R03 o R04.
R02	idCliente nulo	135.080	132.518	-2.562	Se conservan como cliente desconocido; la diferencia son filas excluidas por R03 o R04.
R03	precioUnitario <= 0	2.517	0	-2.517	Se excluyen de fac_ventas en su

					totalidad, tal como define la regla.
R04	fechaFactura inválida (texto ni número de serie Excel)	0	0	0	No se detectaron fechas inválidas en el dataset cargado.
R05	Descripción inconsistente por codigoProducto	644	3.958	n/a	Antes: códigos con más de una descripción en staging. Después: total de productos ya consolidados en dim_producto (una descripción por código).

Confirmación de carga: SELECT COUNT(*) FROM stg_onlineretail devuelve 541.909 filas, igual al archivo de origen. Consultas ejecutadas el 09/10/2026 sobre dw_onlineretail.

Evidenciar la automatización de procesos de base datos (Obligatorio).

Evidencia incorporada en el Anexo E-04: captura de pantalla de la ejecución en SSMS confirmando 541.909 filas en staging (SELECT COUNT(*) FROM stg_onlineretail), ejecutada el 09/10/2026 (ver Anexos).

3.4.4 OLAP, reportes y dashboards

El dashboard de Power BI, conectado al datamart dw_onlineretail, se organiza en tres páginas con un menú lateral para moverse entre ellas y tres filtros compartidos en la parte superior (Mes, País y Producto) que actúan sobre los visuales de la página activa.

La primera página, Desempeño general, concentra los indicadores de resultado agregado: Ticket Promedio por mes (gráfico de columnas), Tasa de Cancelación frente a su meta de 14% (gráfico de gauge) y la evolución mensual de Ingresos Brutos, Ingresos Netos y Monto Cancelado (gráfico de líneas). Estos tres visuales responden a la pregunta de negocio del Capítulo I sobre el desempeño económico general del período analizado (2010-2011).

La segunda página, Productos y mercados, responde a qué productos y países generan más valor: un gráfico de barras horizontales con el top de productos por Ingresos Brutos, y otro con Ingresos Brutos por País ordenado de mayor a menor, donde Reino Unido concentra la mayor parte de los ingresos frente al resto de los países.

La tercera página, Clientes, agrupa los indicadores de comportamiento de cliente: tres tarjetas (Tasa de Recompra, Clientes en Riesgo y Ticket Promedio), un gauge de Tasa de Riesgo frente a su meta de 25%, un gráfico de líneas de Clientes Activos por mes, un gauge de Tasa de Recompra frente a su meta de 72%, y una tabla de Recencia de Cliente ordenada por días sin comprar, que sirve de insumo directo para campañas de retención.

En conjunto, el dashboard cubre los 10 KPI definidos en la Tabla 3.4 (3.4.1), todos calculados con medidas DAX sobre el modelo en estrella de fac_ventas, y los tres filtros compartidos permiten analizar cada indicador por mes, país y producto sin duplicar visuales. El criterio de diseño visual siguió el principio de un gráfico por decisión de negocio: se evitó repetir el mismo tipo de visual para preguntas distintas, por ejemplo la Tasa de Cancelación se representa con un gauge contra meta y no con una barra simple, para que se lea de un vistazo si el indicador está dentro o fuera del objetivo. Las capturas de las tres páginas están en el Word de evidencias del equipo, código E-09.

3.5 Diseño de la solución Big Data

Sección pendiente de realización (indicación del profesor, sesión del curso): esta entrega se enfoca en Business Intelligence; el diseño de la solución Big Data (3.5.1 a 3.5.5) se

desarrollará en la etapa del curso dedicada a Big Data (Unidad III del sílabo). La parte teórica ya cubierta está en la sección 2.3.

3.5.1 Justificación y requisitos Big Data

Cuantifique la necesidad: tamaño y crecimiento de datos, tasa de llegada, variedad, complejidad, latencia, concurrencia u otra condición que supere o complemente el enfoque convencional.

3.5.2 Arquitectura y componentes

Documente ingesta batch/streaming, almacenamiento, particionamiento, procesamiento distribuido, orquestación, consulta/serving, monitoreo y seguridad. Indique la función y versión de cada componente.

3.5.3 Modelo y ciclo de vida de datos

Describa formatos, esquemas, particiones, catálogo/metadatos, linaje, retención, calidad y tratamiento de datos incompletos, duplicados o tardíos.

3.5.4 Escalabilidad, resiliencia y operación

Defina cómo se evaluarán rendimiento, escalabilidad, uso de recursos, tolerancia a fallos y recuperación. Distinga capacidades implementadas de propuestas futuras.

3.5.5 Resultados

Evidencia de funcionamiento de la solución como: visualización de datos (Python, Power BI, etc.)

3.6 Seguridad, privacidad y riesgos

Esta sección cubre la solución de Inteligencia de Negocios, ya implementada; los riesgos específicos de la solución Big Data se completarán cuando esa solución se implemente (sección 3.5).

Privacidad. El dataset es público, tiene licencia CC BY 4.0 y no contiene nombres, correos ni documentos de identidad: CustomerID es un número anónimo (ver 1.6). El equipo trata este identificador únicamente como clave de agrupación estadística, y el dashboard mostrará datos agregados, no registros individuales.

Tabla 3.10. Registro de riesgos de la solución de Inteligencia de Negocios

ID	Riesgo	Probabilidad	Impacto	Control
RS-01	Pérdida o corrupción de datos durante el ETL	Media	Alto	Staging como copia fiel sin modificar; reseteo e identidades controladas con DBCC CHECKIDENT antes de cada carga.
RS-02	Cálculo incorrecto de KPI por cancelaciones, fechas mal interpretadas o filas duplicadas	Alta	Alto	Separación explícita de ventas y cancelaciones (dim_tipotransaccion); conversión robusta de fechas (3.4.3); reconciliación de conteos.
RS-03	Error de carga masiva por formato de archivo (columnas desplazadas, fechas como número de serie)	Alta (ya ocurrió dos veces durante la ejecución, ver 3.4.3)	Alto	Extracción con archivo delimitado por tabulaciones; columna fechaFactura como texto con conversión robusta.
RS-04	Acceso no autorizado a la base de datos o al futuro dashboard	Baja	Medio	Autenticación de Windows; roles con mínimo privilegio (Tabla 3.11); sin credenciales escritas en los scripts.
RS-05	Retraso frente al calendario del curso, al depender de la solución Big Data, aún no implementada; el dashboard de Power BI y el	Media	Alto	Avanzar el informe y el modelo de datos ahora; dejar explícitamente pendiente y priorizada la sección de Big Data (Power BI y el repositorio ya se

	repositorio del equipo ya se completaron (3.4.4 y 5.1).			completaron, 3.4.4 y 5.1).

Tabla 3.11. Roles y permisos previstos

Rol	Permisos	Justificación
Administrador de base de datos (equipo)	Control total sobre la base dw_onlineretail; ejecuta el ETL y los respaldos.	Responsable de la carga y la integridad del modelo.
Analista de datos	Lectura del datamart (consultas sobre fac_ventas y dimensiones).	Análisis sin poder alterar el modelo.
Usuario de negocio	Solo lectura del dashboard de Power BI (ya construido, ver 3.4.4; archivo .pbix publicado en el repositorio, ver 5.1).	Mínimo privilegio.

Respaldo y recuperación. La base dw_onlineretail puede restaurarse por completo reejecutando los dos scripts del ETL (Script 1 y Script 2), ya que el staging conserva una copia fiel del archivo de origen; no se requiere alta disponibilidad por tratarse de un entorno académico, pero sí un respaldo (BACKUP DATABASE) restaurable antes de cada entrega.

3.7 Plan de despliegue y aceptación

Entornos. SQL Server (motor local, instancia del equipo) administrado desde SQL Server Management Studio (SSMS); Power BI Desktop para la capa de visualización (ya instalado y configurado, dashboard funcional, ver 3.4.4). No se usa un entorno de nube de pago (restricción de infraestructura, 1.4).

Dependencias. Archivo Online Retail exportado desde Excel como texto delimitado por tabulaciones; la ruta del archivo en el equipo se parametriza en el Script 2 mediante la variable @ARCHIVO.

Pasos de despliegue. (1) crear la base de datos y las siete tablas (dimensiones, staging y fac_ventas) con el Script 1; (2) ejecutar el Script 2 completo (reseteo, extracción a staging, carga de las cinco dimensiones, carga de la tabla de hechos y verificación) en una sola corrida; (3) conectar Power BI Desktop (ya instalado, versión 2.158.1304.0) a la base mediante autenticación de Windows y crear el archivo .pbix (dashboard ya construido y funcional, ver 3.4.4; archivo .pbix publicado en el repositorio, ver 5.1).

Rollback. El Script 2 es reejecutable: su primer paso vacía fac_ventas y las dimensiones y reinicia sus identidades (DBCC CHECKIDENT) antes de volver a cargar, de modo que una ejecución fallida se puede revertir volviendo a correr el script completo desde el inicio.

Responsables. El equipo del proyecto administra y ejecuta los scripts (ver 5.6, con los nombres y aportes individuales de cada integrante).

Criterios de aceptación. La extracción se acepta cuando SELECT COUNT(*) FROM stg_onlineretail es igual al número de filas del archivo de origen (541,909); la carga de hechos se acepta cuando no existen llaves foráneas huérfanas en fac_ventas respecto de sus dimensiones. Ambos criterios se cumplieron en la ejecución registrada en el Capítulo VI.

Demostración funcional. Se realizará mostrando el dashboard de Power BI (ya finalizado, ver 3.4.4) conectado en vivo a la base dw_onlineretail, durante la sustentación del proyecto ante el profesor.

CAPÍTULO IV: DISEÑO DEL EXPERIMENTO

4.1 Pregunta experimental, objetivo e hipótesis

Pregunta experimental. Cuanto demora el proceso de ETL de la solución de Inteligencia de Negocios en extraer, limpiar y cargar el total de 541,909 registros del dataset

Online Retail en el modelo dimensional, y como cambia el rendimiento de las consultas del datamart frente al volumen de datos cargado.

Objetivo del experimento. Medir el tiempo y la tasa de error del proceso ETL implementado, y comparar el tiempo de respuesta de consultas analíticas tipo OLAP sobre el modelo dimensional ya cargado, para verificar el cumplimiento de las metas de los requisitos RNF-03 y RNF-04 (3.1).

Resultado esperado. Se espera que el ETL cargue el 100% de las filas conciliadas en un tiempo acotado (a medir) y que las consultas sobre el modelo dimensional respondan más rápido que consultas equivalentes directamente sobre la tabla de staging, debido al uso de llaves sustitutas e índices sobre las llaves foráneas de fac_ventas. No se formula una hipótesis estadística formal: el enfoque es comparativo y descriptivo, apropiado para un volumen de datos fijo y conocido.

Relación con los objetivos del proyecto. El experimento valida el objetivo específico 1 del proyecto (1.3) y aporta la línea base de rendimiento que servirá de referencia cuando se incorpore la comparación con la solución Big Data.

4.2 Escenario y datasets

DATASET	FUENTE Y VERSIÓN	VOLUMEN / FORMATO	CALIDAD Y PRIVACIDAD	USO EN BI / BIG DATA	EVIDENCIA
Online Retail	UCI Machine Learning Repository, Chen (2015), CC BY 4.0	541,909 filas, 8 columnas; archivo .xlsx exportado a texto delimitado por tabulaciones para la carga	Sin datos personales identificables; CustomerID nulo en una parte de las filas (por cuantificar, 6.1); cancelaciones con prefijo "C"	BI, dataset en uso, ya cargado en su totalidad al modelo dimensional. Será también la base de la solución Big Data cuando esta se defina (2.3)	E-01, E-04 (ver Anexos)
Archivo intermedio de staging	Generado por el equipo a partir de Online Retail	Texto delimitado por tabulaciones (.txt), mismas 541,909 filas	Formato corregido tras depuración (3.4.3): tabulador como separador, fecha como texto	BI, insumo directo del BULK INSERT (Script 2, Paso 2)	E-03, E-04
Dataset de la solución Big Data	Pendiente de definir (se usará el mismo Online Retail salvo que el curso indique otro requisito)	Pendiente de definir	Pendiente de definir	Big Data, pendiente de ejecución (3.5)	Pendiente

4.3 Variables, métricas y criterios de aceptación

TIPO	VARIABLE / MÉTRICA	DEFINICIÓN Y UNIDAD	MÉTODO DE MEDICIÓN	META / UMBRAL
Independiente	Volumen de datos procesado	Número de filas cargadas en staging (filas)	SELECT COUNT(*) FROM stg_onlineretail	541,909 (volumen fijo de la solución BI)
Dependiente, BI	Tiempo total de ejecución del ETL	Segundos desde el inicio hasta el fin del Script 2 (proceso ETL completo)	Cronometrado con tabla temporal global ##etl_timing (SYSDATETIME al inicio y al fin del Script 2); registrado en 6.2.	4 segundos medidos en la ejecución oficial (09/10/2026); meta operativa RNF-04: menos de 60 segundos.
Dependiente, BI	Tiempo de respuesta de consulta OLAP	Milisegundos, tiempo total de ejecución promedio de una consulta analítica típica (ingresos por mes y país) sobre fac_ventas	Estadísticas de cliente de SSMS (Ctrl+Shift+S), promedio de varias ejecuciones; registrado en 4.5 (E2) y 6.3 (EXP-01).	Meta operativa RNF-03: menos de 5000 ms (5 segundos) por visual; resultado: 52,5 ms sin índices y 40,0 ms con índices (ver 6.3, EXP-01), muy por debajo de la meta.

TIPO	VARIABLE / MÉTRICA	DEFINICIÓN Y UNIDAD	MÉTODO DE MEDICIÓN	META / UMBRAL
Dependiente, BI	Tasa de reconciliación de filas	Filas cargadas en staging / filas del archivo de origen, en porcentaje	SELECT COUNT(*) FROM stg_onlineretail contra el conteo del archivo	100% (cumplido: 541,909 / 541,909)
Dependiente, Big Data	Métrica de la solución Big Data	Pendiente de definir junto con la implementación de esa solución (3.5)	Pendiente de definir	Pendiente de ejecución

4.4 Entorno, herramientas y reproducibilidad

Motor de base de datos: SQL Server, administrado con SQL Server Management Studio (SSMS) 20. Herramienta de BI: Power BI Desktop, versión 2.158.1304.0, instalado desde Microsoft Store (la más reciente disponible a la fecha). Equipo de ejecución: Windows 11 Pro (64 bits), procesador Intel Core i5-12400F (12 CPU), 16 GB de RAM, placa ASRock B660M Pro RS. La reproducibilidad del experimento no depende de hardware específico: el ETL corre íntegramente en el motor de base de datos (T-SQL) y solo requiere una instancia de SQL Server con el archivo Online Retail exportado en el formato descrito en 3.4.3; los tiempos reportados en el Capítulo VI corresponden a este equipo y pueden variar en otro hardware.

COMPONENTE	VERSIÓN / CONFIGURACIÓN	PROPÓSITO	EVIDENCIA
Motor de base de datos	Microsoft SQL Server 2022 (RTM-GDR) (KB5122771), verificado con SELECT @@VERSION el 09/10/2026; base de datos dw_onlineretail; administrado con SSMS 20	Almacenar staging y modelo dimensional; ejecutar el ETL en T-SQL	E-12
Herramienta de administración	SQL Server Management Studio 20 (acceso directo instalado, verificado el 09/10/2026)	Ejecutar y depurar los scripts del ETL	E-12
Sistema operativo y hardware	Windows 11 Pro (64 bits); procesador Intel Core i5-12400F (12 CPU); 16 GB de RAM; placa base ASRock B660M Pro RS	Entorno de ejecución del motor de base de datos y de SSMS	E-12
Visualización	Power BI Desktop, versión 2.158.1304.0 (Microsoft Corporation, instalado desde Microsoft Store, 2.69 GB)	Dashboard conectado al datamart mediante autenticación de Windows	E-12

4.5 Matriz de escenarios experimentales

ID	SOLUCIÓN	CAMBIO / CONFIGURACIÓN	DATOS	MÉTRICAS	CONTROLES	RESULTADO ESPERADO
E1	BI	Ejecución completa del ETL (Script 1 y Script 2) sobre el dataset completo	541,909 registros (Online Retail)	Tiempo total, tasa de reconciliación	Misma secuencia de scripts; base reseteada antes de cada corrida (DBCC CHECKIDENT)	Carga del 100% de las filas conciliadas en un tiempo acotado y repetible Resultado obtenido: 100% de las filas conciliadas (541,909) en 4 segundos (ejecución del 09/10/2026).
E2	BI	Consulta OLAP típica (ingresos por mes y país) sobre fac_ventas, con y sin índices sobre las llaves foráneas	Modelo dimensional ya cargado (541,909 filas de origen)	Tiempo de respuesta de la consulta (ms)	Misma consulta, mismo filtro, ejecutada varias veces para promediar	La consulta con índices responde en menos tiempo que sin índices, y en ambos casos por debajo de la meta RNF-03

ID	SOLUCIÓN	CAMBIO / CONFIGURACIÓN	DATOS	MÉTRICAS	CONTROLES	RESULTADO ESPERADO
E3	Big Data (pendiente de ejecución, 3.5)	Pendiente de definir cuando se diseñe la solución Big Data	Pendiente de definir	Pendiente de definir	Pendiente de definir	Pendiente de definir

4.6 Procedimiento reproducible

- Preparar y validar el entorno a partir de una versión identificada del repositorio.
- Obtener el dataset original y verificar integridad, licencia y perfil de calidad.
- Ejecutar la preparación/transformación y registrar el dataset procesado y sus controles.
- Ejecutar cada escenario con la misma política de calentamiento, caché, concurrencia y número de repeticiones.
- Capturar automáticamente logs, tiempos, uso de recursos, errores y resultados de negocio.
- Consolidar resultados, calcular medidas resumen y variabilidad, generar tablas y visualizaciones.
- Contrastar resultados con los criterios de aceptación y registrar desviaciones o incidentes.

4.7 Riesgos, validez y limitaciones del experimento

El dataset corresponde a una sola empresa minorista del Reino Unido durante un periodo acotado (diciembre de 2010 a diciembre de 2011), por lo que los tiempos y patrones medidos no son generalizables a otros negocios o mercados. El equipo mide los escenarios E1 y

E2 en un único equipo de cómputo no dedicado (sin aislar otros procesos en ejecución), lo que introduce variabilidad entre corridas; se mitigará repitiendo cada medición al menos tres veces y reportando el promedio y la variación. El escenario E3 (Big Data) y su entorno de ejecución dependen de implementar la solución diseñada en 3.5, por lo que no es posible hoy anticipar sus limitaciones específicas. Finalmente, al no existir aún una línea base de metas numéricas para los requisitos no funcionales (RNF-03, RNF-04), los resultados de este capítulo se usan en primera instancia para fijar esas metas, y no para aprobarlas o rechazarlas.

CAPÍTULO V: IMPLEMENTACIÓN Y CONTROL DE EVIDENCIAS

5.1 Estructura y versión del repositorio

Repositorio. El proyecto se aloja en GitHub: https://github.com/Juanhp07/Base-de-datos-Avanzada-y-Big-Data-Proyecto, repositorio público, rama única main (sin tags). Último commit registrado: 5e06932 («Estructuracion de archivos del repo», 20/10/2026). El commit final, correspondiente a la entrega del informe y el Word de evidencias, se registrará al cierre del proyecto.

Estructura de carpetas. dataset/ (Online Retail.xlsx, onlineretail.txt), scripts/ (script_1_creacion_bd.sql, script_2_etl.sql), power-bi/ (dashboard_bi.pbix), además de .gitignore y README.md en la raíz. Las carpetas documentacion/ (informe final y Word de evidencias) y big-data/ se incorporan en las siguientes entregas, cuando se suban esos archivos y se desarrolle la fase de Big Data (ver 2.3 y 3.5).

Instrucciones de ejecución. (1) Clonar el repositorio; (2) ejecutar scripts/script_1_creacion_bd.sql en SSMS para crear la base dw_onlineretail y sus siete tablas; (3) ejecutar scripts/script_2_etl.sql para el proceso ETL completo; (4) abrir power-

bi/dashboard_bi.pbix en Power BI Desktop y actualizar la conexión a la base local (detalle completo en 3.7).

Licencias y dependencias. El repositorio no incluye un archivo de licencia propio; el dataset de origen Online Retail está bajo licencia CC BY 4.0 (UCI Machine Learning Repository, Chen, 2015). Dependencias: SQL Server 2019 o superior (o Express), SQL Server Management Studio (SSMS) y Power BI Desktop.

5.2 Implementación de la solución BI

A la fecha de este informe se implementaron y ejecutaron los dos scripts T-SQL descritos en 3.4.2 y 3.4.3: creación de la base de datos y las siete tablas (Script 1) y el proceso ETL completo -reseteo, extracción a staging mediante BULK INSERT con SQL dinámico, carga de las cinco dimensiones, carga de la tabla de hechos fac_ventas y verificación- (Script 2). La ejecución completa cargó el 100% de los 541,909 registros de Online Retail, tras corregir dos errores reales de conversión de datos (formato del archivo exportado y fechas como número de serie de Excel, documentados en 3.4.3). El dashboard de Power BI conectado al modelo ya está implementado y documentado (ver 3.4.4 y 6.4, evidencia E-09). Los scripts y el archivo .pbix están publicados en el repositorio del equipo (ver 5.1).

5.3 Implementación de la solución Big Data

Documente ingesta, almacenamiento, procesamiento, particionamiento/distribución, consultas, orquestación, monitoreo y evidencias. Incluya comandos, scripts o notebooks ejecutables y archivos de configuración.

5.4 Calidad, seguridad y pruebas

ID PRUEBA	REQUISITO	ENTRADA / CONDICIÓN	RESULTADO ESPERADO	RESULTADO	EVIDENCIA
PR-01	RNF-01 (integridad de la carga)	Ejecución completa del Script 2 sobre el archivo de origen	COUNT(*) en staging = 541,909	Conforme: 541,909 filas cargadas, sin filas descartadas por error	E-05
PR-02	RF-BI-03 (modelo dimensional sin huérfanos)	Carga de fac_ventas tras cargar las cinco dimensiones (Script 2, Paso 4)	Toda llave foránea de fac_ventas existe en su dimensión	Conforme (las llaves se resuelven por JOIN desde el staging; sin registros huérfanos)	E-06, E-07
PR-03	RNF-02 (repetibilidad) y manejo de fechaFactura inválida	Reejecución completa de el Script 2 tras el reseteo (Paso 1, DBCC CHECKIDENT)	Mismos conteos y totales en una segunda ejecución	Conforme: la segunda ejecución, ya con fechaFactura como varchar y conversión robusta, no presentó errores	E-05
PR-04	Solución Big Data (pendiente de ejecutar, 3.5)	Pendiente de ejecutar	Por definir	Pendiente de ejecución	Pendiente

5.5 Registro de retroalimentación y mejoras

FECHA	RETROALIMENTACIÓN	ACCIÓN / DECISIÓN	EVIDENCIA ANTES-DESPUÉS	RESP.
09/10/2026 *Fecha real de la retroalimentación del docente o del equipo.*	El docente señaló que los indicadores y el modelo dimensional deben responder directamente a las preguntas de negocio y a los stakeholders del Capítulo I, y no copiarse de un ejemplo sin entender su lógica.	Se definieron los KPI (Tabla 3.4) y el modelo dimensional (3.4.2) a partir del problema y los objetivos propios del proyecto, adaptando (sin copiar) la estructura y la convención de nombres del ejemplo del curso.	Tabla 3.4 y esquema físico (Figura 2) propios del proyecto	Equipo
10/10/2026	Primer error de ejecución real: BULK INSERT falló por conversión de datos en la columna "cantidad" al cargar un archivo CSV separado por comas.	Se identificó que la columna descripcionProducto contiene comas internas y desplaza columnas; se cambió la extracción a texto delimitado por tabulaciones y el FIELDTERMINATOR a CHAR(9).	Mensaje de error de SSMS (antes) frente al avance de la carga (después); ver 3.4.3	Equipo
10/10/2026	Segundo error de ejecución real: BULK INSERT falló por conversión de datos en la columna "fechaFactura", a partir de la fila 26,734.	Se redefinió fechaFactura como varchar(30) y se agregó la conversión robusta con TRY_CONVERT e ISNUMERIC/DATEADD para los casos de número de serie de Excel.	"(0 filas afectadas)" con error (antes) frente a "541909 filas afectadas" / totalStaging = 541909 (después)	Equipo

5.6 Contribuciones individuales

INTEGRANTE	RESPONSABILIDADES	COMMITS / ARTEFACTOS	VALIDACIÓN DEL EQUIPO	%
Imán Giraldo, A. (Tomas)	Diseñó la base de cada sección del Power BI y su estructura, organizando los gráficos en 3 hojas; reorganizó los gráficos y mejoró su funcionamiento con las pruebas de la solución BI OLAP. Responsable de los puntos 1 y 4 del informe.	«Diseño de graficos bi Tomas», «Ajustar Graficos bi Tomas»	Sí, confirmado por el equipo	100% (de su parte asignada)
Huertas Pérez, J. (Juan)	Estructuró el informe y la creación de la base de datos, dividió las partes, revisó y completó la información obtenida, estructuró las pruebas del ETL y del SQL, elaboró el documento de evidencias, creó y organizó el repositorio del proyecto, y estructuró la idea del Power BI.	«Se subio el excel con la fuente original de datos del OnlineRetail», «feat: actualizar dashboard de Power BI OnlineRetail.pbix», «Verificacion de graficos del bi», «Implementacion de todas las medidas completas», «verificacion de la totalidad e integridad de archivos del repo», «Estructuracion de archivos del repo»	Sí, confirmado por el equipo	100% (de su parte asignada)
Herrada Vela, E. (Estefanno)	Agregó filtros y mejoró la capa visual de los gráficos del Power BI, corrigió problemas con las medidas y la conexión con la base de datos. Responsable, junto con Fabrizzio, del punto 3 del informe.	«Modificacion de graficos», «Primer Cambio Estefanno»	Sí, confirmado por el equipo	100% (de su parte asignada)

INTEGRANTE	RESPONSABILIDADES	COMMITS / ARTEFACTOS	VALIDACIÓN DEL EQUIPO	%
Pilco Sosa, S. (Samanta)	Mejoró los gráficos, ajustó títulos, subtítulos y leyendas, integró las medidas de los KPI y verificó que todos los KPI y gráficos funcionaran correctamente. Responsable de los puntos 6, 7 y 8 del informe.	«Arreglo de gráficos»	Sí, confirmado por el equipo	100% (de su parte asignada)
Bueno Fernández, C. (Fabrizzio)	Generó y guió los gráficos de los primeros 5 KPI, integró el código de las medidas y la estructura de los gráficos. Responsable de las pruebas del BI y del SQL sobre el ETL, la verificación del esquema estrella y la validación de todos los puntos del informe.	«ModificacionFabrizziopbi», «CambioFabrizziopbi», «PrimerCambioFabrizziopbi»	Sí, confirmado por el equipo	100% (de su parte asignada)

5.7 Declaración de uso responsable de inteligencia artificial

HERRAMIENTA	FINALIDAD	CONTENIDO UTILIZADO	VERIFICACIÓN HUMANA	RIESGOS / PRIVACIDAD
Claude (Anthropic), asistente de IA conversacional	Generación de ideas para enfocar el proyecto, y apoyo para estructurar la información del informe en un orden lógico (qué va en cada capítulo y sección).	Descripciones generales del proyecto y del dataset (sin datos personales); borradores de organización de contenido del informe.	El equipo revisó y decidió qué ideas incorporar y en qué orden, ajustando la estructura final según el criterio propio y la pauta del curso.	No se compartieron datos personales ni archivos originales del dataset.
Claude (Anthropic), asistente de IA conversacional	Investigación sobre el dataset y sus fuentes (origen, licencia, características), y apoyo para resolver errores concretos durante la ejecución de los scripts T-SQL del proceso ETL.	Metadatos públicos del dataset Online Retail (UCI Machine Learning Repository); mensajes de error de SSMS y fragmentos de código T-SQL.	Cada corrección se probó y verificó en SSMS por el equipo antes de aceptarla; los errores reales de carga (ver 3.4.3) se diagnosticaron y confirmaron de forma conjunta contra el resultado esperado.	No se ingresaron datos personales; solo estructuras de tablas, fragmentos de código y mensajes de error.
Claude (Anthropic), asistente de IA conversacional	Consejos y recomendaciones sobre qué tipo de gráfico usar para cada indicador de la solución de Inteligencia de Negocios, y ayuda para descartar información o datos que no resultaban válidos o confiables para el análisis.	Lista de KPI e indicadores definidos por el equipo (3.4.1); criterios generales de visualización de datos.	El equipo construye y valida el dashboard directamente en Power BI Desktop, decidiendo qué recomendaciones aplicar según los datos reales disponibles.	Sin datos personales; solo nombres de indicadores y criterios generales de diseño.

Perplexity, motor de búsqueda con IA	Búsqueda de información de apoyo (conceptos generales, buenas prácticas de modelado e Inteligencia de Negocios) para complementar el desarrollo del proyecto.	Consultas generales sobre conceptos del curso; ningún dato del dataset ni del proyecto se cargó en esta herramienta.	El equipo contrastó la información encontrada contra el material del curso y las fuentes citadas en el informe antes de usarla.	No se ingresó información del proyecto ni datos personales.
Claude (Anthropic), asistente de IA conversacional	Apoyo para identificar qué conversiones y qué código eran necesarios para preparar el archivo de texto (.txt) a partir del dataset en Excel, de modo que el proceso de carga (BULK INSERT) lo leyera correctamente.	Estructura y formato del archivo de texto exportado del dataset (columnas, separadores, codificación); fragmentos de código T-SQL relacionados con la carga.	El equipo probó cada ajuste sugerido en SSMS y verificó que el archivo cargara correctamente, sin alterar los datos originales del dataset, antes de incorporarlo al proceso.	No se compartieron datos personales; solo la estructura del archivo y mensajes relacionados con su formato.
Claude (Anthropic), asistente de IA conversacional	Orientación sobre cómo estructurar y organizar las carpetas y archivos del repositorio del proyecto en GitHub.	Lista de archivos y carpetas del proyecto (dataset, scripts, Power BI); buenas prácticas generales de organización de repositorios.	El equipo definió y aplicó la estructura final de carpetas directamente en el repositorio, ajustándola según sus propios criterios.	No se compartió información personal ni credenciales; solo nombres de carpetas y archivos del proyecto.
Claude (Anthropic), asistente de IA conversacional	Apoyo para saber cómo cronometrar la ejecución de los procesos (ETL, consultas) y qué opciones activar en SQL Server para medir esos tiempos.	Fragmentos de código T-SQL y nombres de opciones de SQL Server (por ejemplo, SET STATISTICS TIME/IO) relacionados con la medición de	El equipo ejecutó las mediciones directamente en SSMS y registró los tiempos reales obtenidos, usados en el informe (ver 6.2 y 6.3).	No se ingresaron datos personales; solo fragmentos de código y resultados de tiempos de ejecución.

		tiempos de ejecución.		

CAPÍTULO VI: EJECUCIÓN, RESULTADOS Y ANÁLISIS DE DATOS

6.1 Validación del dataset original y procesado

CONTROL	ORIGINAL	PROCESADO	REGLA / UMBRAL	RESULTADO Y EVIDENCIA
Total de filas	541,909 (archivo Online Retail)	541,909 (tabla stg_onlineretail)	Deben coincidir al 100%	Conforme. SELECT COUNT(*) FROM stg_onlineretail = 541,909 (evidencia E-05).
Filas con CustomerID nulo	135.080	135.080 (conservadas en fac_ventas, asociadas al cliente "desconocido")	Se documenta, no se exige un umbral (se conservan en fac_ventas como cliente "desconocido")	Conforme: SELECT COUNT(*) FROM stg_onlineretail WHERE idCliente IS NULL = 135.080 (09/10/2026).
Filas con cantidad o importe negativo (cancelaciones)	9.288	9.288 (clasificadas en fac_ventas como tipo "C", separadas del importe de ventas en K2)	Se documenta y se separa por tipo de transacción (dim_tipotransaccion = "C"), no se descarta	Conforme: SELECT COUNT(*) FROM stg_onlineretail WHERE numeroFactura LIKE 'C%' = 9.288 (09/10/2026).

CONTROL	ORIGINAL	PROCESADO	REGLA / UMBRAL	RESULTADO Y EVIDENCIA
Filas con precioUnitario menor o igual a 0	2.517	0 (excluidas en la carga de fac_ventas)	No deben llegar a fac_ventas (condición WHERE precioUnitario > 0 en el Script 2, Paso 4)	Conforme: SELECT COUNT(*) FROM stg_onlineretail WHERE precioUnitario <= 0 = 2.517 filas, excluidas en la carga de fac_ventas (condición WHERE precioUnitario > 0 en el Script 2, Paso 4), ejecutado el 09/10/2026.

6.2 Registro de ejecuciones

Se registran las ejecuciones del Script 2 (proceso ETL completo), incluyendo las tres corridas del paso de extracción a staging (Script 2, Paso 2) necesarias hasta lograr una carga exitosa, la carga de dimensiones y de la tabla de hechos, y la corrida oficial completa cronometrada con la tabla temporal ##etl_timing.

Tabla 6.1. Registro de ejecuciones del ETL (Script 2)

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
1	09/10/2026	Extracción a staging (Script 2, Paso 2)	Archivo exportado como CSV separado por comas; FIELDTERMINATOR = ','	Falló: error de conversión de datos en la columna 4 (cantidad), por comas internas en descripcionProducto que desplazan columnas.

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
2	09/10/2026	Extracción a staging (Script 2, Paso 2), tras corregir el delimitador	Archivo exportado como texto delimitado por tabulaciones; FIELDTERMINATOR = CHAR(9)	Avanzó más allá del error anterior, pero falló en la fila 26,734: error de conversión en la columna 5 (fechaFactura), por fechas guardadas como número de serie de Excel.
3	09/10/2026	Extracción a staging (Script 2, Paso 2), tras redefinir fechaFactura como varchar(30)	Mismo archivo .txt; columna fechaFactura como texto, sin conversión forzada en la carga	Exitosa: "541909 filas afectadas"; SELECT COUNT(*) AS totalStaging = 541909, igual al archivo de origen.
4	09/10/2026	Carga de dimensiones (Script 2, Paso 3)	Ejecutado sobre el staging ya cargado (541,909 filas)	Exitosa: las cinco dimensiones se poblaron sin errores reportados por el equipo.

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
5	09/10/2026	Carga de la tabla de hechos (Script 2, Paso 4)	INSERT...SELECT con CROSS APPLY para resolver la fecha y JOIN contra las cinco dimensiones	Exitosa, según lo reportado por el equipo; conteo final verificado: SELECT COUNT(*) FROM fac_ventas = 529.293 filas (09/10/2026).
6	09/10/2026	Ejecución oficial completa del ETL (Script 1 y Script 2, los cinco pasos)	Staging reseteado a 0 antes de cargar (tras un intento previo en que había quedado con 2,167,636 filas, 541,909 x 4, por ejecutar la extracción varias veces sin truncar); cronometrada con la tabla temporal ##etl_timing	Exitosa: ejecución limpia y única, 2026-10-09 20:06:23 a 20:06:27 (4 segundos en total); 541.909 filas en staging; 5.310.802 unidades cargadas en fac_ventas

Verificación de repetibilidad (RNF-02): la Ejecución 6 documentada en la fila anterior corresponde a la corrida limpia tras resetear el staging; en un intento previo de esa misma sesión de trabajo, el staging había quedado con 2,167,636 filas (541,909 x 4) por ejecutar la extracción (BULK INSERT) varias veces sin truncar la tabla antes de cada corrida, error detectado y corregido antes de continuar con la carga de dimensiones y hechos.

6.3 Tabla consolidada de resultados

ESCENARIO	SOLUCIÓN	ESCALA / CONFIG.	LATENCIA	THROUGHPUT	RECURSOS / CALIDAD	EVID.
EXP-01	BI	302 filas agregadas (ingresos por mes y país); sin índices vs. con 3 índices no clusterizados sobre las FK de fac_ventas	52,5 ms sin índices / 40,0 ms con índices (tiempo total de ejecución, promedio de 6 y 5 corridas)	~5.750 filas/s sin índices / ~7.550 filas/s con índices	Tiempo de espera en el servidor: 44,0 ms sin índices / 31,6 ms con índices	E-13
EXP-02	Big Data	<<Valor>>	<<ms/s>>	<<MB-s/eventos-s>>	<<CPU/RAM/nodos>>	E-08
EXP-03	Comparativo	<<Valor>>	<<ms/s>>	<<Unidad>>	<<Valor>>	E-09

6.4 Visualizaciones y dashboards

En la página Desempeño general, el gráfico de Ticket Promedio por mes permite decidir si conviene ajustar promociones para acercar el ticket a la meta de GBP 550 (K4); el gauge de Tasa de Cancelación frente a su meta de 14% permite decidir si se requieren acciones correctivas de calidad de servicio (K5); y la evolución mensual de Ingresos Brutos, Ingresos Netos y Monto Cancelado permite decidir si el desempeño económico del período se aleja de las metas de crecimiento del 10% (K1, K2, K3).

En la página Productos y mercados, el top de productos por Ingresos Brutos permite decidir qué productos priorizar en catálogo y reposición (K6); el gráfico de Ingresos Brutos por País permite decidir en qué mercados, además de Reino Unido, conviene invertir para reducir la concentración actual de 84,6% (K9).

En la página Clientes, las tarjetas de Tasa de Recompra, Clientes en Riesgo y Ticket Promedio, junto con sus gauges, permiten decidir si la base de clientes activos crece según la meta (K7), si la fidelización se acerca al 72% de recompra (K8) y si la tasa de clientes en riesgo baja hacia el 25% (K10); la tabla de Recencia de Cliente permite decidir a qué clientes específicos dirigir las campañas de retención, priorizando por días sin comprar.

Para la solución Big Data no hay visualizaciones ni salidas que incluir todavía, porque esa sección está pendiente de realización hasta la etapa del curso dedicada a Big Data (ver 3.5); la evidencia E-10 queda pendiente de ejecución.

Figura 6.1. Dashboard de Power BI, página Desempeño general

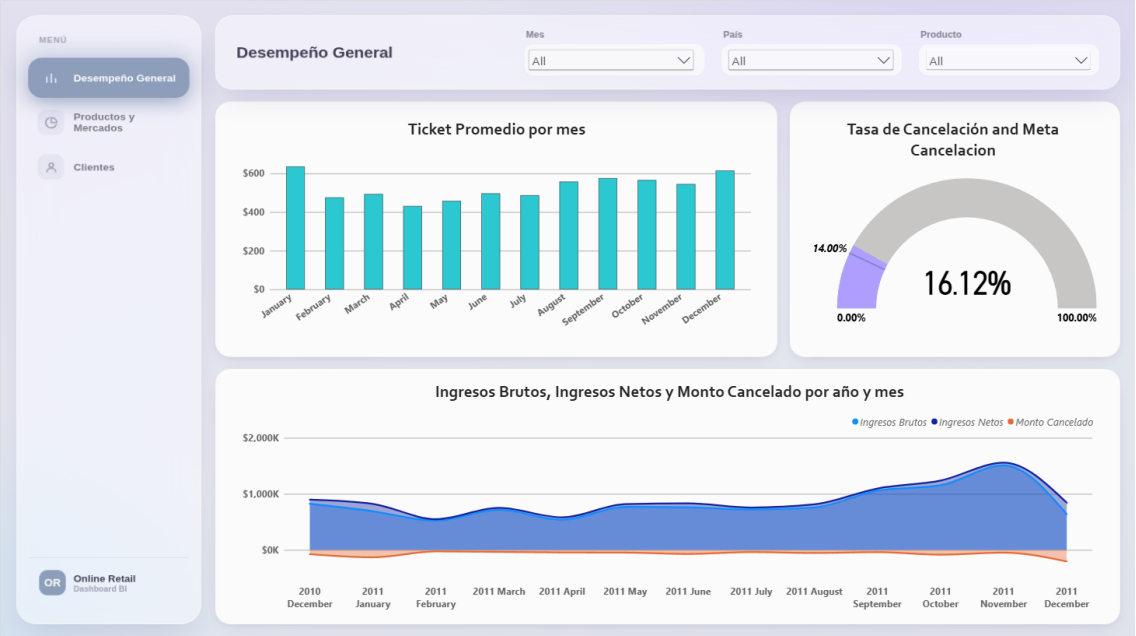


Figura 6.2. Dashboard de Power BI, página Productos y mercados

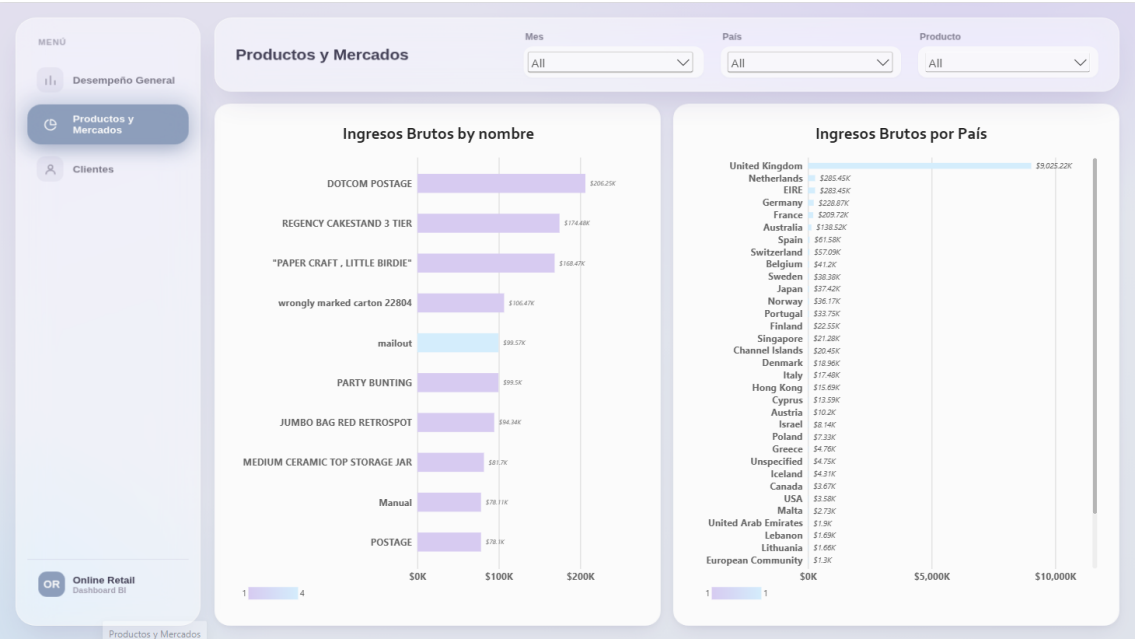
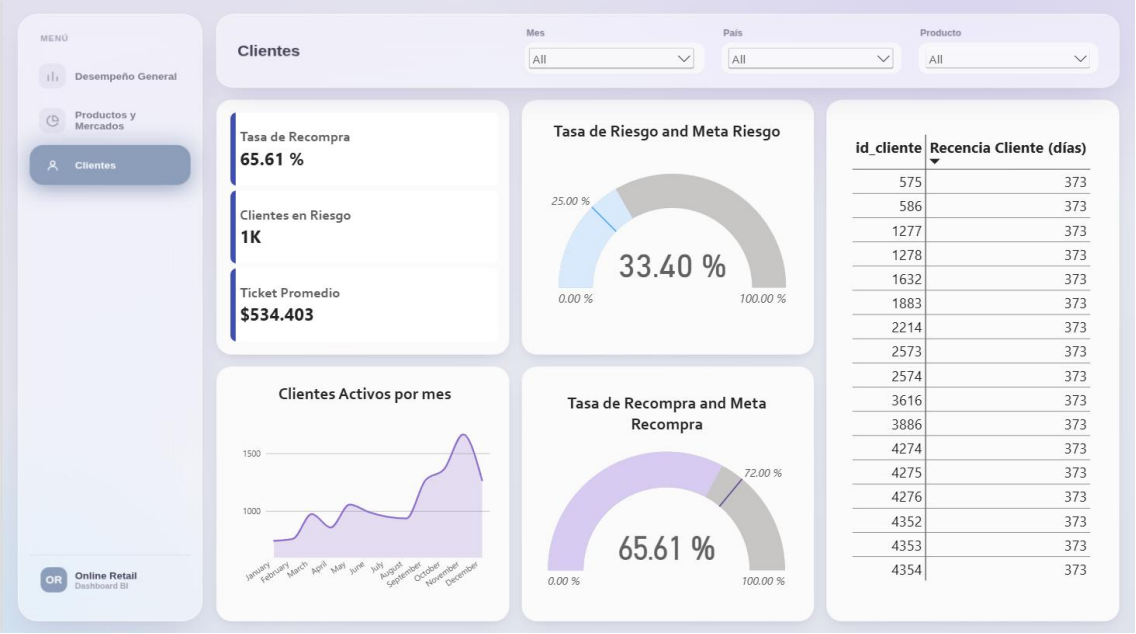


Figura 6.3. Dashboard de Power BI, página Clientes



Las mismas capturas, junto con el detalle de fecha y responsable de cada una, también están disponibles en el Word de evidencias del equipo, código E-09, publicado en el repositorio (ver 5.1).

6.5 Análisis e interpretación técnica

- **Contraste con las metas.** De los diez KPI definidos en la Tabla 3.4, algunos resultados ya alcanzan la meta propuesta y otros aún no. La Tasa de Cancelación (K5) se ubica en 16,12%, por encima de la meta de 14% o menos. La Tasa de Recompra (K8) alcanza 69,98%, cerca de la meta de 72% pero sin llegar a cumplirla. La concentración de ingresos en Reino Unido (K9) es de 84,6%, por encima de la meta de reducirla a 80%. La Tasa de Riesgo de Abandono (K10) es de 33,40%, con una brecha considerable respecto a la meta de 25%. En el proceso ETL, el tiempo de consulta OLAP bajó de 52,5 ms sin índices a 40,0 ms con tres índices no clusterizados (EXP-01, 6.3), una mejora cercana al 24%, y la carga del ETL concilió el 100% de las 541.909 filas del

dataset en 4 segundos de ejecución oficial, cumpliendo el objetivo de integridad planteado para el experimento (RNF-01, RNF-04).

- **Comparación de escenarios.** El único escenario con resultados completos hasta el momento es EXP-01 (BI, consulta sin índices frente a consulta con tres índices no clusterizados sobre las llaves foráneas de fac_ventas): agregar los índices redujo la latencia de 52,5 ms a 40,0 ms y el tiempo de espera en el servidor de 44,0 ms a 31,6 ms, una mejora de rendimiento medible pero moderada, esperable dado que la consulta de prueba agrega solo 302 filas. Los escenarios de Big Data (EXP-02) y el comparativo entre ambas soluciones (EXP-03) todavía están pendientes de ejecutar (ver 3.5), por lo que, por ahora, la comparación de rendimiento y escalabilidad queda limitada a la solución de Business Intelligence.

- **Patrones, errores y limitaciones.** El registro de ejecuciones del ETL documenta dos intentos fallidos antes de la carga exitosa: el primero por comas internas en la descripción de producto que desplazaban columnas durante el BULK INSERT con delimitador de coma, y el segundo por fechas almacenadas como número de serie de Excel en la columna fechaFactura. El perfilado de calidad (Tabla 3.9 y 3.10) identificó 135.080 filas sin cliente identificado, que se conservaron como cliente “desconocido” en vez de descartarse, 9.288 filas de cancelación separadas por tipo de transacción, y 2.517 filas con precio unitario menor o igual a cero, que sí se excluyeron de la tabla de hechos. En cuanto a patrones de negocio, la concentración del 84,6% de los ingresos en un solo país (Reino Unido) constituye un riesgo de mercado que el propio dashboard expone en la página Productos y mercados.

- **Compromisos de ingeniería.** Conservar las filas sin cliente identificado como "desconocido", en vez de descartarlas, prioriza la completitud de los ingresos totales por encima de la precisión del análisis a nivel de cliente individual. Incorporar los tres índices no clusterizados mejora la latencia de consulta, pero añade un costo de almacenamiento y de mantenimiento en cada ejecución del ETL. El tratamiento tipo 1 (sobrescritura) aplicado a las dimensiones de cliente, producto y país simplifica el modelo dimensional, a cambio de no conservar el historial de cambios de esos atributos. Por último, las metas de los diez KPI están definidas como valores fijos dentro de las medidas DAX del dashboard, una solución simple de implementar en el tiempo del proyecto, pero menos mantenible si esas metas cambian en el futuro (ver recomendación R1, 7.3).

- **Límites de la inferencia.** La mejora de latencia observada al incorporar índices no permite afirmar una relación causal generalizable, dado que se midió sobre una sola consulta de prueba (302 filas agregadas) y un número reducido de corridas (entre 5 y 6), sin un diseño estadístico que aísle otras variables del servidor. Tampoco puede sostenerse que un cliente con recencia mayor a 90 días vaya a abandonar la relación comercial: ese umbral es una regla de negocio definida por el equipo para priorizar campañas de retención (K10), no una predicción validada con un modelo de abandono. Finalmente, todos los resultados corresponden a una sola empresa minorista del Reino Unido durante un periodo acotado (diciembre de 2010 a diciembre de 2011), por lo que no deben generalizarse a otro negocio, mercado o periodo sin repetir el análisis sobre datos propios.

6.6 Verificación de funcionalidad y completitud

PRODUCTO	CRITERIOS DE ACEPTACIÓN	RESULTADO	ESTADO	EVIDENCIA
Modelo dimensional (esquema estrella)	Siete tablas creadas; llaves primarias y foráneas definidas (3.4.2)	Base de datos dw_onlineretail creada con dim_cliente, dim_producto, dim_pais, dim_tiempo, dim_tipotransaccion, stg_onlineretail y fac_ventas	Completo	E-03
ETL (staging, dimensiones y hechos)	100% de filas conciliadas; sin llaves huérfanas (RNF-01)	541,909 filas cargadas en staging; dimensiones y fac_ventas poblados sin errores tras las correcciones de 3.4.3	Completo	E-05, E-06, E-07
Dashboard de Power BI	Conexión al datamart; KPI y filtros según 3.3	Dashboard de 3 páginas conectado al datamart, con los 10 KPI (Tabla 3.4) y los filtros Mes/País/Producto (ver 3.4.4).	Completo	E-09

CAPÍTULO VII: CONCLUSIONES TÉCNICAS Y RECOMENDACIONES

7.1 Matriz objetivo-resultado-conclusión-recomendación

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
OE-01 (BI)	10 KPI (K1-K10, Tabla 3.4) con medidas DAX sobre el modelo en estrella; ETL concilia el 100% de las filas (541.909/541.909, RNF-01); dashboard de 3 páginas con filtros compartidos.	El modelo dimensional y el ETL cumplen el objetivo: cargan y concilian el 100% del dataset y alimentan un dashboard funcional que cubre los 10 KPI definidos, sin llaves foráneas huérfanas (RF-BI-03).	Migrar los umbrales de meta (14%, 25%, 72%, etc.) de las medidas DAX a una tabla paramétrica del modelo, para ajustarlos desde Power BI sin editar fórmulas.	E-03, E-05, E-09
OE-02 (Big Data)	Sección pendiente de realización (3.5); no se ejecutó procesamiento distribuido en esta entrega.	Aún no hay resultados para evaluar el desempeño de un componente de Big Data; el objetivo específico 2 queda pendiente de implementación.	Implementar la segmentación RFM sobre Spark en la Unidad III del curso, reutilizando fac_ventas y dim_cliente ya construidos como fuente de datos.	E-10 (pendiente)

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
OE-03 (Experimentación)	ETL completo en 4 s (RNF-04, meta < 60 s); consulta OLAP típica en 52,5 ms sin índices y 40,0 ms con 3 índices no clusterizados, 24% más rápida (RNF-03, meta < 5000 ms); repetibilidad confirmada en la Ejecución 6 (RNF-02).	El diseño experimental es reproducible y todas las métricas de rendimiento medidas están muy por debajo de sus metas, lo que indica margen para escalar el volumen de datos sin comprometer los tiempos de respuesta.	Aprovechar ese margen para ampliar el experimento con una comparación directa contra la solución Big Data cuando esta se incorpore (EXP-02 y EXP-03 de la Tabla 6.3, hoy pendientes).	E-05, E-13
OE-04 (Ética y gobierno de datos)	Dataset público bajo licencia CC BY 4.0, sin PII más allá del CustomerID anonimizado original; principal sesgo identificado: una sola empresa del Reino Unido con clientes mayoristas (8.1).	El uso de los datos cumple con el uso responsable planteado en el objetivo: procedencia, licencia y limitaciones quedaron documentadas y no se requirió anonimización adicional.	Mantener esta documentación de licencia y sesgos actualizada en el repositorio (5.1) y repetirla si se incorpora una fuente de datos distinta para el componente Big Data.	8.1

7.2 Conclusiones técnicas

C1. El proceso ETL carga y concilia el 100% de las filas del dataset (541.909 de 541.909, RNF-01) en 4 segundos de ejecución oficial (RNF-04), muy por debajo del umbral de 60 segundos definido como meta, lo que confirma que el diseño del modelo dimensional (3.4.2) y el reseteo con DBCC CHECKIDENT antes de cada carga (6.2) cumplen su objetivo de repetibilidad (RNF-02).

C2. El dashboard de Power BI (E-09) responde consultas analíticas típicas (ingresos por mes y país) en 52,5 ms sin índices y en 40,0 ms con 3 índices no clusterizados sobre las llaves foráneas de fac_ventas, una mejora del 24% (EXP-01, E-13), muy por debajo de la meta de 5000 ms definida para RNF-03.

C3. Sobre la línea base calculada el 09/10/2026, la Tasa de Cancelación (K5) es de 16,12% frente a la meta de 14%, y la concentración de ingresos en Reino Unido (K9) es de 84,6% frente a la meta de 80%, lo que indica que, aunque el modelo y el dashboard funcionan correctamente, el negocio todavía no alcanza dos de sus diez metas de KPI y requiere acciones comerciales fuera del alcance técnico de este proyecto.

C4. El componente de Big Data (OE-02) no pudo evaluarse en esta entrega porque la Unidad III del curso, que cubre procesamiento distribuido, aún no se dicta; en consecuencia, los escenarios EXP-02 y EXP-03 de la Tabla 6.3 permanecen pendientes y la comparación de rendimiento entre BI y Big Data queda para una entrega posterior.

7.3 Recomendaciones

R1. Prioridad alta, impacto en mantenibilidad: mover los umbrales de meta de los 10 KPI (14%, 25%, 72%, etc.), hoy fijos en las medidas DAX, a una tabla paramétrica del modelo dimensional, para poder actualizarlos desde Power BI sin modificar fórmulas ni volver a publicar el .pbix.

R2. Prioridad media, impacto en escalabilidad: dado que la consulta OLAP de prueba bajó de 52,5 ms a 40,0 ms al agregar 3 índices no clusterizados (EXP-01), evaluar índices adicionales sobre las demás columnas de filtro usadas por el dashboard (Mes, Producto) si el volumen de datos crece más allá del dataset actual.

R3. Prioridad alta, impacto en cobertura del proyecto: implementar el componente de Big Data (OE-02, segmentación RFM sobre Spark) en cuanto el curso cubra la Unidad III, reutilizando

fac_ventas y dim_cliente como fuente, para poder completar los escenarios EXP-02 y EXP-03 pendientes de la Tabla 6.3.

R4. Prioridad media, impacto en gestión de datos: automatizar la verificación de conciliación (RNF-01) y de repetibilidad (RNF-02) con una consulta de validación que se ejecute al final del Script 2, en vez de revisarla manualmente en SSMS, para reducir el riesgo de repetir el error de staging documentado en 6.2.

CAPÍTULO VIII: RESPONSABILIDAD ÉTICA Y PROFESIONAL

8.1 Tratamiento ético, legal y seguro de los datos

El dataset Online Retail es de dominio público bajo licencia Creative Commons Attribution 4.0 (CC BY 4.0), por lo que su uso, adaptación y redistribución con atribución están autorizados por el propietario de los datos (Chen, 2015); no se requiere un consentimiento adicional porque no se trata de datos recolectados directamente por el equipo. El dataset no contiene nombre, correo electrónico ni documento de identidad: el campo CustomerID es un identificador numérico anónimo asignado por el propietario original, por lo que no se aplicó un proceso adicional de anonimización, siguiendo el principio de minimización (solo se usan las columnas necesarias para el análisis de ventas y de clientes). La retención de los datos se limita a los repositorios académicos del equipo y del curso, sin publicación externa. El principal sesgo identificado es que el dataset corresponde a una única empresa del Reino Unido especializada en artículos de regalo, con una proporción relevante de clientes mayoristas, por lo que los indicadores no son generalizables a otros giros de negocio o mercados. La explicabilidad de los indicadores de la solución de Inteligencia de Negocios es alta, porque cada KPI se define con una fórmula trazable hasta columnas concretas del modelo dimensional (Tabla 3.4). Como consecuencia del uso de resultados, el equipo se compromete a presentar los indicadores como

una ayuda a la decisión y no como una conclusión definitiva sobre clientes o productos individuales.

8.2 Impactos de las soluciones

En el plano organizacional, la solución de Inteligencia de Negocios reduce el tiempo dedicado a reportes manuales en hojas de cálculo (1.1) y ofrece una fuente única y conciliada de indicadores. En el plano social, una futura segmentación de clientes podría usarse para dirigir campañas de marketing diferenciadas, lo cual es legítimo sobre datos anónimos, pero debe evitar prácticas discriminatorias si en algún momento se cruzara con datos adicionales que sí identifiquen personas; esta investigación no cruza ni planea cruzar dicha información. En el plano económico, el principal riesgo es que decisiones de inventario o de campañas de marketing se tomen exclusivamente a partir de un indicador, sin revisión humana, cuando el dataset no es representativo de todos los mercados o periodos del negocio (riesgo ya identificado como RS-05 en 3.6); se mitiga presentando los resultados como apoyo a la decisión, con sus limitaciones explícitas. El impacto ambiental de la solución es bajo y se limita al consumo computacional de ejecutar el ETL en SQL Server, dentro de un entorno académico de un solo nodo.

8.3 Compromiso profesional

El equipo es responsable de la exactitud de los scripts, de la interpretación de los indicadores y de documentar honestamente el estado de avance del proyecto, incluyendo las partes aún pendientes (solución Big Data), en lugar de presentarlas como terminadas. El equipo reconoce los límites de su competencia: no son administradores de bases de datos profesionales ni científicos de datos certificados, por lo que las decisiones de arquitectura (Capítulo III) se sustentan en la bibliografía citada y en la evidencia recogida durante la propia ejecución del proyecto, y no en experiencia previa en producción. La transparencia y la reproducibilidad se abordan dejando los dos scripts del ETL (Script 1 y Script 2) documentados y ejecutables en

orden (3.4.3 y 3.7), de modo que otra persona pueda repetir la carga y obtener el mismo resultado de 541,909 filas conciliadas. Para evitar la manipulación o el uso indebido de los datos y los resultados, el equipo se compromete a no alterar los datos de origen fuera de las reglas de limpieza documentadas (3.4.3, Tabla 3.9), a no seleccionar únicamente los resultados favorables al reportar las mediciones del Capítulo IV, y a declarar explícitamente el uso de herramientas de inteligencia artificial como apoyo, conforme a la declaración de la sección 5.7.

REFERENCIAS BIBLIOGRÁFICAS

ABET. (2026). Criteria for Accrediting Engineering Programs, 2026-2027. https://www.abet.org/accreditation/accreditation-criteria/criteria-for-accrediting-engineering-programs-2026-2027/

ABET. (s. f.). Assessment Planning. https://www.abet.org/accreditation/get-accredited/assessment-planning/

Chen, D. (2015). Online Retail [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C5BW33

Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining. Journal of Database Marketing & Customer Strategy Management, 19(3), 197–208. https://doi.org/10.1057/dbm.2012.17

Coronel-Alayo, A. B., Castillo-Domínguez, P. G., & Davila-Rodriguez, V. E. (2021). Business intelligence system in the administration of crops for agricultural production. 19th LACCEI International Multi-Conference for Engineering, Education, and Technology. https://doi.org/10.18687/LACCEI2021.1.1.262

Inmon, W. H. (2005). Building the data warehouse (4.a ed.). Wiley.

Kimball, R., & Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3.a ed.). Wiley.

Risco-Ramos, R. H., Pérez-Aguilar, D. A., Casaverde-Pacherrez, L. A., Malpica Rodríguez, M., Pérez-Aguilar, J. M., & Pérez-Aguilar, A. P. (2023). Using a business intelligence framework and data mining as computational tools in SMEs: Production forecasting of a hydroelectric power plant as a case study. 21st LACCEI International Multi-Conference for Engineering, Education, and Technology. https://doi.org/10.18687/LACCEI2023.1.1.832

Vargas Rios, B. L., Guarniz Castañeda, D. R., & Castillo Dominguez, P. G. (2025). Datamart application in decision making for exporting companies in La Libertad, Perú. 23rd LACCEI

International Multi-Conference for Engineering, Education, and Technology.
https://doi.org/10.18687/LACCEI2025.1.1.1096

ANEXOS Y MANIFIESTO DE EVIDENCIAS

CÓDIGO	EVIDENCIA	UBICACIÓN / ENLACE	VERSIÓN / FECHA	RESPONSABLE
E-01	Dataset original Online Retail (.xlsx)	Repositorio del equipo (ver 5.1)	Chen (2015), UCI	Equipo
E-02	Script 1, creación de la base de datos y las siete tablas	Repositorio del equipo (ver 5.1)	Actividad 07, curso BASAV	Equipo
E-03	Script 2 (Pasos 1-2), reseteo de tablas y extracción a staging (BULK INSERT con SQL dinámico)	Repositorio del equipo (ver 5.1)	Actividad 07, versión corregida (tabulador, fechaFactura texto)	Equipo
E-04	Captura de pantalla de la ejecución exitosa: "541909 filas afectadas" / totalStaging = 541909	Este informe, sección 3.4.3	20/10/2026	Equipo
E-05	Script 2 (Paso 3), carga de las cinco dimensiones	Repositorio del equipo (ver 5.1)	Actividad 07	Equipo
E-06	Script 2 (Paso 4), carga de la tabla de hechos fac_ventas	Repositorio del equipo (ver 5.1)	Actividad 07	Equipo
E-07	Diagrama de arquitectura de la solución de Inteligencia de Negocios (Figura 1)	Este informe, sección 3.3	Versión actual del informe	Equipo
E-08	Diagrama del esquema estrella implementado (Figura 2)	Este informe, sección 3.4.2	Versión actual del informe	Equipo

CÓDIGO	EVIDENCIA	UBICACIÓN / ENLACE	VERSIÓN / FECHA	RESPONSABLE
E-09	Dashboard de Power BI	Este informe, sección 3.4.4 y 6.4; también en el Word de evidencias del equipo	Octubre 2026	Equipo
E-10	Evidencia de la solución Big Data	Pendiente de ejecutar (3.5)	Pendiente	Equipo
E-11	Repositorio del proyecto (README, estructura de carpetas, licencias)	https://github.com/Juanhp07/Base-de-datos-Avanzada-y-Big-Data-Proyecto	main, commit 5e06932, 20/10/2026	Equipo
E-12	Capturas de propiedades de SSMS 20, especificaciones del equipo (sistema operativo, procesador, RAM, placa base) y versión instalada de Power BI Desktop	Este informe, sección 4.4	09/10/2026	Equipo
E-13	Prueba de tiempo de respuesta OLAP (sin y con índices)	Word de evidencias del equipo, código E-13; resultados también en 4.3 (RNF-03) y 6.3 (EXP-01)	Octubre 2026	Equipo

Lista de anexos sugeridos

- Anexo A. Requisitos, historias de usuario y criterios de aceptación.
- Anexo B. Diccionario de datos, modelos y diagramas de arquitectura.
- Anexo C. Fichas de datasets original, procesado y de prueba.

- Anexo D. Scripts SQL, notebooks y archivos de configuración (el componente Big Data se agregará cuando esa solución se defina, ver 2.3).
- Anexo E. Logs, tablas completas, visualizaciones y capturas de ejecución.
- Anexo F. Manual de instalación, despliegue, operación y demostración.
- Anexo G. Evidencia de retroalimentación, mejoras y aceptación.
- Anexo H. Historial de repositorio y aportes individuales.
- Anexo I. Declaración de uso responsable de IA.

DECLARACIÓN DE USO RESPONSABLE DE INTELIGENCIA ARTIFICIAL

La IA puede utilizarse como apoyo, pero no reemplaza el análisis, la simulación, la interpretación de resultados ni la responsabilidad académica del estudiante/equipo.

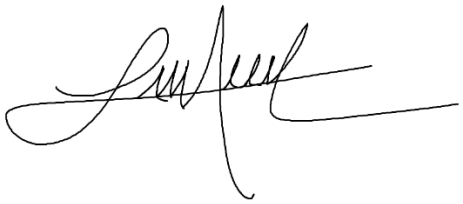
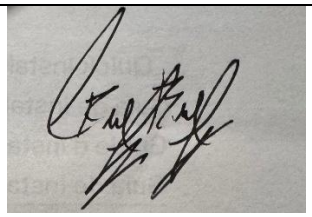
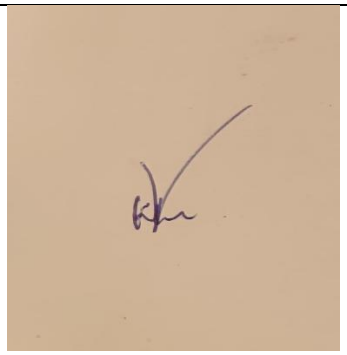
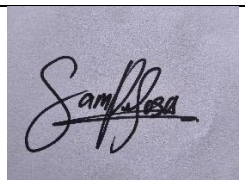
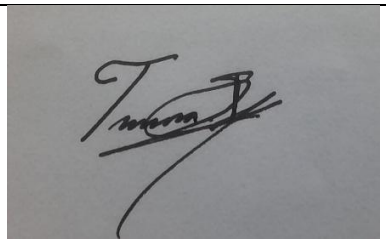
Responda de manera honesta:

Aspecto	Respuesta
1. ¿Utilicé IA?	☐ No ☐ Sí
2. Herramienta	☐ ChatGPT ☐ Gemini ☐ Copilot ☐ Claude ☐ Otra: Perplexity
3. ¿Para qué la utilicé?	☐ Ideas ☐ Redacción ☐ Código ☐ Errores ☐ Gráficos ☐ Análisis ☐ Otra: Organizacion de repositorio y cronometraje en procesos
4. ¿En qué parte?	☐ Diagrama ☐ Código ☐ Resultados ☐ Análisis ☐ Conclusiones ☐ Reporte ☐ Otra: Carpetas en el repositorio, cronometraje en sql, guias para verificar el código y su integridad de funcionamiento.
5. ¿Cómo validé lo que la IA me proporcionó?	☐ Ejecuté el código ☐ Comparé resultados ☐ Revisé fórmulas/unidades ☐ Validé con simulador ☐ Corregí errores

Mas información detallada en la tabla de Declaración de uso responsable de inteligencia artificial**.**

Declaración ética

Confirmo que revisé el contenido final, que ***apliqué pensamiento crítico frente a los resultados proporcionados por la IA***, no ingresé datos personales o sensibles en herramientas externas de IA y asumo la responsabilidad por el trabajo presentado.

Nombre(s)	**Firmas**
Juan Huertas Perez	
Fabrizzio Bueno Fernandez	
Estefanno Herrada Vela	
Samanta Pilco Sosa	
Tomas Iman Giraldo	
Fecha 21/10/2026	

Revisión rápida del docente:

☐ Declara uso de IA.

☐ Evidencia validación manual.

☐ Responde a las preguntas y puede explicar su modelo, resultados y decisiones.

Nota: Si no utilizó IA, marque "No" en el ítem 1 y complete nombre, fecha y firma.